2026 年 CIMC“西门子杯”中国智能制造挑战赛

智能制造创新研发类赛项：工业硬件研发

赛题二：边缘 AI 电子系统设计方向

工程设计方案

参赛队伍编号：2026462686

2026 年 7 月 06 日

基于GD32H759的云台式边缘AI停车智能管理系统

摘要

针对传统停车管理中人工巡检效率低、固定摄像头覆盖盲区多、车辆信息采集不灵活以及复杂光照环境下识别稳定性不足等问题，本文设计了一种基于GD32H759 的二轴云台停车智能管理系统。系统以移动巡检小车为载体，构建RK3588 上位机导航规划—下位机底盘运动控制—GD32H759端侧视觉感知与云台跟踪的分层协同架构，实现停车场及道路违停场景下的图像采集、车牌检测、字符识别、目标跟踪、数据交互与自主巡检等功能。硬件层面，系统以GD32H759为核心控制单元，结合OV2640 摄像头、LCD显示屏、二轴无刷云台、电机驱动模块、CAN/串口通信接口及分级供电保护电路，完成图像输入、模型推理、结果显示和执行控制。软件层面， 系统采用模块化设计，将图像采集、数据预处理、AI 推理、检测后处理、字符识别、结果滤波、云台控制和通信输出等功能解耦，提高了系统调试、维护和扩展能力。算法层面， 本文采用YOLO-FastestV2 作为车牌检测模型，在192×192 输入图像上完成车牌区域定位，并通过Anchor 解码、置信度筛选和非极大值抑制获得检测框；随后利用LPRNet Tiny 对裁剪后的94×24灰度车牌图像进行逐字符识别，并结合车牌编码规则与多帧投票机制提升识别稳定性。针对嵌入式平台存储空间和计算资源受限的问题，系统进一步采用INT8 量化、静态内存管理和轻量化模型部署方式，以降低模型存储占用和端侧推理延迟。本文还从模型结构、特征响应、检测框解码、字符概率分布、显著性定位和量化误差补偿等角度对YOLO-FastestV2 与LPRNet Tiny 进行了可解释性分析，说明模型输出结果由图像特征逐步推导至检测框和车牌字符序列的过程。研究表明， 该系统能够为室外停车场、园区道路、开放式停车区域和违停巡检场景提供一种低成本、实时性强、可扩展的边缘AI 解决方案，对嵌入式视觉识别、移动机器人巡检和智能停车管理系统设计具有一定参考价值。

关键词:边缘 AI；智能停车管理；YOLO-FastestV2；LPRNet Tiny；车牌识别

目录

1 项目概况 1

1.1 选题背景 1

1.2 项目目标与核心功能 2

1.2.1 项目目标 2

1.2.2 核心功能 3

1.2.3 本小节内容 4

1.2.4 技术路线 5

2 需求分析与应用场景论证 7

2.1 应用场景描述 7

2.2 系统功能需求分析 8

2.3 系统性能需求分析 9

3 系统架构设计 12

3.1 系统功能架构 12

3.2 系统硬件架构 14

3.2.1 底盘原理分析 14

3.2.2 二轴云台电机驱动及相机原理分析 15

3.2.3 相机与 LCD 原理分析 16

3.3 系统软件架构 17

3.4 系统可扩展性设计 19

3.4.1 硬件可扩展性 19

3.4.2 软件功能模块可扩展性 20

3.4.3 算法模型可扩展性 20

3.4.4 数据层可扩展性 21

3.4.5 应用场景可扩展性 22

4 数据集方案 23

4.1 数据来源 23

4.2 数据预处理 25

4.3 数据分布分析 27

5 边缘 AI 模型开发流程 29

5.1 模型架构选型与设计 29

5.2 模型训练与验证 31

5.2.1 训练环境与框架 31
5.2.2 训练超参数配置 31
5.2.3 训练过程与收敛分析 33
5.2.4 模型验证结果 35
5.2.5 模型优化与压缩 36
5.3 边缘部署 39
5.3.1 边缘 AI 部署步骤 39
5.3.2 端侧推理性能评估 41
6 系统软硬件设计方案 43
6.1 系统硬件总体方案 43
6.1.1 硬件功能模块划分 44
6.1.2 供电与资源配置方案 44
6.2 系统原理图设计 45
6.2.1 电源输入与稳压电路设计 46
6.2.2 主控最小系统与通信接口设计 47
6.2.3 电机驱动与电流采样电路设计 47
6.2.4 摄像头图像采集接口设计 48
6.3 系统软件总体方案 48
6.4 系统模块设计 51
6.4.1 数据采集模块 51
6.4.2 端侧数据预处理模块 51
6.4.3 后处理与决策模块 52
6.4.4 人机交互模块 53
7 系统测试评估 54
7.1 系统测试与性能评估 54
7.2 端侧 AI 推理性能评估 55
7.3 通信与控制性能评估 55
7.4 运动控制与安全保护评估 56
7.5 综合评价 57
8 模型可解释性分析 58
8.1 YOLO-FastestV2 模型 58
8.1.1 输入预处理与坐标映射 58
8.1.2 卷积特征提取过程 59

8.1.3 检测头输出与边界框推导 60
8.1.4 置信度筛选、NMS 与最终检测框 60
8.1.5 INT8 量化误差与检测解释性 62
8.2 LPRNET 模型可解释性 63
8.2.1 识别输入形成过程 63
8.2.2 前向传播与逐字符概率推导 64
8.2.3 损失函数与整牌准确率 64
8.2.4 字符置信度、规则约束与多帧投票 66
8.2.5 LPRNet 误差来源 67
8.2.6 检测—识别级联模型 68
9 总结与展望 69
参考文献 71
附录 73

1 项目概况

1.1选题背景

随着城市机动车保有量持续增长，传统停车管理方式在车辆识别、车位引导、巡检管理和异常处理等方面逐渐暴露出效率低、人工依赖强、响应不及时等问题，如图 1-1 所示。尤其在室外禁止停车区域、商业综合体停车场和园区停车场中，车辆流动频繁、环境光照复杂、车位分布密集，仅依靠固定摄像头和人工巡查难以及时、准确地完成车辆信息采集与场内管理。因此，研究一种集视觉识别、移动巡检、云台跟踪和路径规划于一体的智能停车管理系统，具有较强的现实意义。



图 1-1　城市道路违停场景

近年来，嵌入式 AI、边缘计算和移动机器人技术快速发展，为停车智能化管理提供了新的技术路径。相比传统依赖云端服务器的识别系统，边缘端 AI 推理能够在本地完成图像处理和目标识别，具有实时性高、网络依赖低、隐私性好等优点[1]。GD32H759 作为高性能嵌入式微控制器，具备较强的运算能力和外设扩展能力，适合承担轻量化 AI 模型

推理、图像采集处理以及云台控制等实时任务。

本课题以“基于 GD32H759 的二轴云台停车智能管理系统”为研究对象，构建由 GD32H759 主体的分层协同系统。其中，GD32H759 负责车牌检测与识别模型推理，并根据视觉检测结果控制二轴云台完成目标位置追踪，该架构将实时视觉感知、底层运动控制和高层导航规划分离，提高了系统的实时性、稳定性和可扩展性。

在违停应用场景中，系统可通过摄像头采集车辆图像，利用端侧 AI 模型完成车牌区域检测和字符识别，并通过二轴云台对目标车辆进行持续跟踪。当系统与移动底盘结合后，可进一步实现停车巡检、车位状态采集、车辆信息登记、异常停车识别和路径引导等功能。相比固定式管理设备，移动式智能管理系统部署更加灵活，能够覆盖固定摄像头盲区，适应不同规模和结构的停车环境。

因此，本项目的研究不仅能够提升违停车辆识别与巡检管理的自动化水平，也对嵌入式 AI 在移动机器人场景中的应用具有一定参考价值。通过在 GD32H759 上实现轻量化模型推理可为低成本、高实时性、可扩展的智能停车管理系统设计提供一种可行方案。

1.2项目目标与核心功能

1.2.1 项目目标

本项目旨在设计并实现一套基于 GD32H759 的二轴云台停车智能管理系统。系统以移动巡检小车为载体，结合嵌入式 AI 视觉识别、二轴云台目标跟踪、底盘运动控制和上位机导航规划等技术，实现道路违停于停车场环境下车辆信息采集、车牌识别、目标跟踪和自主巡检等功能。

系统总体目标是构建“GD32H759 端侧感知与云台控制+下位机底盘执行 +上位机导航规划”的分层协同架构。其中，GD32H759 负责摄像头图像采集、AI 模型推理、车牌检测识别以及云台位置追踪；下位机负责小车底盘电机控制，保证运动执行的稳定性；上位机负责区域地图构建、定位导航、路径规划和任务调度。通过多模块协同，提高停车管理的自动化、实时性和智能化水平。

本项目希望解决传统停车管理中人工巡检效率低、固定摄像头覆盖范围有限、车辆信息采集不灵活等问题，使系统能够在复杂道路违停与停车场环境中完成车辆识别、区域巡检和目标跟踪，为后续扩展车位引导、异常停车检测、无人值守管理等功能提供基础。

1.2.2 核心功能

1) 图像采集与显示功能

系统通过摄像头实时采集环境图像，并在 GD32H759 端完成图像帧读取、格式转换和 LCD 显示。采集到的图像作为 AI 模型输入，用于后续车牌检测与识别。同时，系统能够在显示屏上叠加车牌检测框、识别结果和运行状态，便于调试与现场观察。

2) 车牌检测与识别功能

GD32H759 端部署轻量化 AI 模型，首先利用车牌检测模型从摄像头图像中定位车牌区域，然后对检测到的车牌区域进行裁剪、缩放、灰度化和量化处理，再送入车牌字符识别模型完成车牌号码识别。系统还对识别结果进行格式判断和多帧滤波，提高车牌识别的稳定性与可靠性。

3) 二轴云台目标跟踪功能

系统根据车牌检测框在图像中的位置计算目标中心与画面中心之间的偏差，并将偏差转换为云台俯仰轴和偏航轴的控制量。GD32H759 通过 CAN 通信控制二轴云台电机，使摄像头能够自动调整方向，将目标车辆保持在画面中心附近，从而提高连续识别和动态巡检能力。

4) 底盘运动控制功能

下位机模块负责小车底盘电机控制，接收上位机或主控模块下发的运动指令，实现前进、后退、转向、停止等基础运动功能。通过将底盘控制与视觉识别、导航规划分离，可以降低系统耦合度，提高运动控制的实时性和稳定性。

5) 定位导航与路径规划功能

RK3588 上位机负责区域环境中的定位、导航和路径规划。系统可根据预设巡检路线或任务目标规划移动路径[2]，并向下位机发送运动控制指令，使小车能够在区域环境内自主移动。该功能为后续实现自动巡检、车位引导和异常区域巡视提供基础。

6) 通信与数据交互功能

系统各模块之间通过串口、CAN 等通信方式进行数据交互[3]。GD32H759 可将识别到的车牌号码、检测状态和云台控制信息输出给其他模块；RK3588 可向下位机发送运动指令，并接收来自感知模块的车辆识别结果。通过规范通信协议，系统能够实现感知、决策和执行之间的协同工作。

7) 异常处理与系统调试功能

系统具备一定的运行状态监测和异常恢复能力。例如，当摄像头长时间未获取有效图像帧时，可进行摄像头恢复处理；当云台 CAN 通信出现异常时，可进行状态检测和总线恢复。同时，系统保留了模型推理结果、识别置信度、云台目标位置、通信发送次数等调试变量，便于后续优化和故障分析。

1.2.3 本小节内容

本小节主要围绕基于 GD32H759 的二轴云台停车智能管理系统的建设目标和核心功能展开说明。在项目目标方面，重点明确系统的总体设计方向、功能实现范围以及各硬件模块之间的任务分工；在核心功能方面，重点阐述系统在图像采集、车牌检测识别、二轴云台目标跟踪、底盘运动控制、定位导航规划、通信交互和异常处理等方面的具体功能需求。

本系统以停车智能管理为应用背景，针对传统停车管理中人工巡检效率低、固定摄像头覆盖范围有限、车辆信息采集不够灵活等问题，提出一种融合嵌入式 AI 识别、二轴云台跟踪、移动底盘控制和上位机导航规划的分层协同系统方案。系统以 GD32H759 为核心边缘感知与控制单元，负责摄像头图像采集、车牌检测识别模型推理以及二轴云台位置追踪；下位机模块负责小车底盘电机控制，实现运动执行；上位机负责环境区域定位、路径规划和任务调度，从而形成感知、决策与执行相互配合的系统结构。

本小节的核心内容是明确系统“要实现什么”和“如何分模块实现”。其中，项目目标主要从系统总体目标、技术实现目标和应用目标三个方面进行阐述；核心功能则围绕系统实际运行流程展开，即先由摄像头采集停车图像，再由 GD32H759 完成车牌检测与识别，根据识别结果控制二轴云台进行目标跟踪，同时由上位机完成导航规划，并通过下位机驱动小车底盘完成移动巡检。通过对项目目标和核心功能的分析，可以为后续系统架构设计、硬件选型、软件模块划分、AI 模型部署和系统测试验证提供依据。

从功能实现角度看，本系统不仅需要完成单一的车牌识别任务，还需要实现视觉识别、云台控制、移动底盘和导航规划之间的协同工作。因此，本小节在内容组织上将系统功能划分为图像采集与显示、车牌检测与识别、二轴云台目标跟踪、底盘运动控制、定位导航与路径规划、通信与数据交互、异常处理与系统调试等部分。通过这种功能划分，可以使系统设计目标更加清晰，也便于后续章节分别展开硬件设计、软件设计和测试验证。

1.2.4 技术路线

本项目面向停车场及道路违停智能管理场景，构建一套以移动巡检车辆为载体的智能巡检系统。系统采用分层式设计思路，由 RK3588 上位机负责定位导航、路径规划和任务调度，下位机负责底盘运动控制，GD32H759 负责端侧图像采集、AI 推理、车牌识别以及二轴云台跟踪控制，如图 1-2 所示。通过多模块协同工作，实现对违停车辆的车牌信息采集、目标跟踪和自主巡检，为停车管理提供更加自动化、智能化的技术支撑。

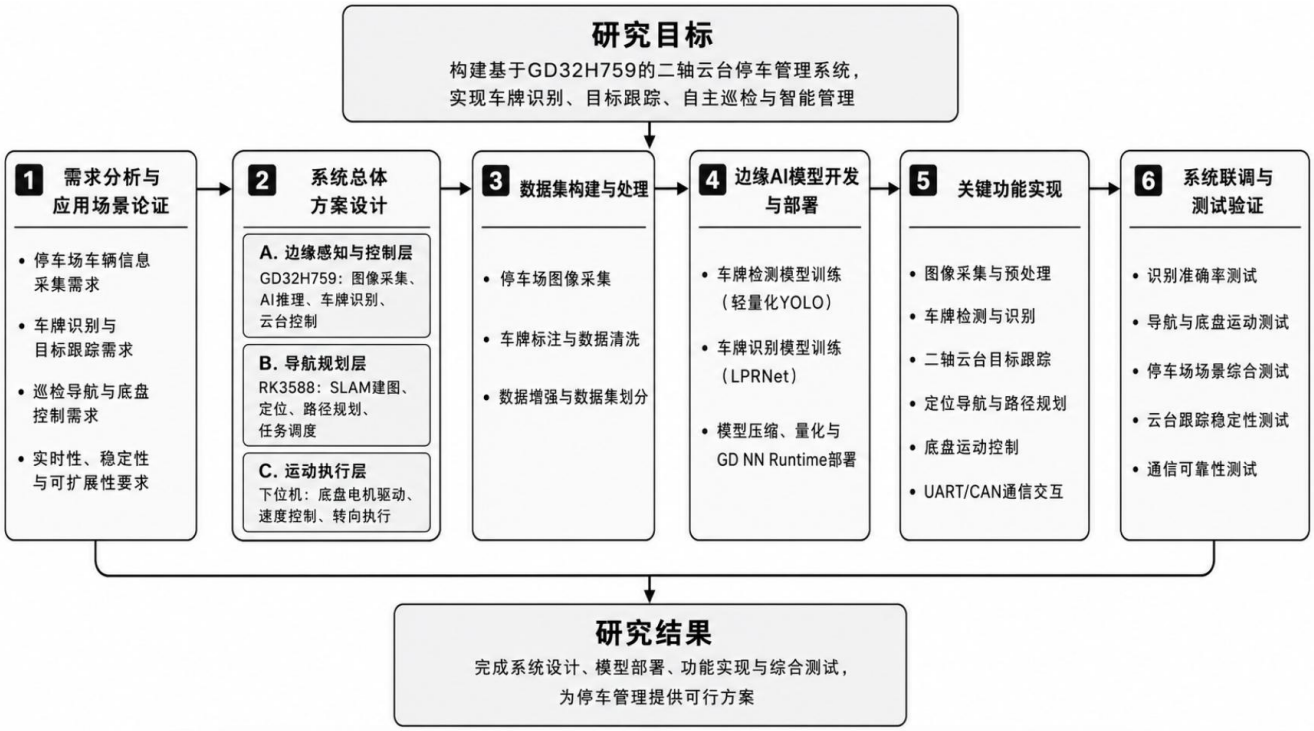


图 1-2　技术路线图

在系统总体架构方面，结合停车智能管理的实际需求，将系统划分为感知层、控制层和决策层。感知层主要由摄像头、GD32H759 和二轴云台组成，用于完成现场图像采集、车牌检测识别以及摄像头姿态调整；控制层由下位机控制板和底盘电机构成，负责接收运动控制指令并驱动小车完成前进、后退、转向和停止等动作；决策层则由 RK3588 上位机构成，承担环境感知、路径规划、巡检任务管理和信息汇总等功能。这样的架构能够使各部分功能边界更加明确，也便于后续调试、维护和功能扩展。

在端侧视觉识别方面，系统首先通过摄像头采集停车区域图像，并对 RGB565 格式的图像数据进行预处理，将其转换为 AI 模型所需的 int8 输入格式。随后，GD32H759 调用车牌检测模型，对图像中的车牌区域进行定位，并通过后处理过程完成检测框解码、置信

度筛选和非极大值抑制，以获得较为准确的车牌位置。对于检测到的车牌区域，系统继续进行裁剪、缩放、灰度化和量化处理，再输入车牌字符识别模型，输出对应的车牌号码。考虑到实际环境中可能存在光照变化、运动模糊或短时遮挡等情况，系统还将对连续多帧识别结果进行滤波和稳定判断，降低单帧误识别对最终结果的影响。

在目标跟踪方面，项目设计了基于车牌检测框位置的二轴云台控制方法。系统实时计算车牌检测框中心点与图像中心点之间的偏差，并根据偏差大小换算出云台偏航轴和俯仰轴的调整量。GD32H759 通过 CAN 通信向云台电机发送位置控制指令，使摄像头能够跟随目标车辆或目标车牌进行角度调整，尽量将车牌保持在画面中心附近。该方法有助于提高动态巡检过程中车牌识别的连续性，减少因视角偏移造成的识别失败。

在移动平台控制与导航方面，RK3588 根据环境地图和巡检任务要求完成路径规划，并将运动控制指令发送至下位机。下位机接收指令后控制底盘电机运行，实现小车在停车区域内的自主移动。与此同时，GD32H759 识别得到的车牌号码、检测状态和目标位置信息可反馈至 RK3588，用于辅助判断车辆状态、记录巡检结果以及执行后续停车管理任务，从而形成“导航—识别—跟踪—反馈”的闭环工作流程。

项目后期将开展系统联调与功能验证。测试内容包括摄像头图像采集、AI 模型推理、车牌检测识别、二轴云台跟踪、底盘运动控制、模块间通信以及路径规划等功能。在单模块测试通过后，进一步进行整机联调，并在道路违停和停车场管理模拟场景中验证系统的车辆识别、目标跟踪和自主巡检效果。通过测试系统在不同场景下的实时性、稳定性和识别准确性，评估该方案在停车智能管理中的应用可行性和扩展价值。

2 需求分析与应用场景论证

2.1应用场景描述

本项目主要面向室外环境、园区露天停车区、商业广场地面停车场、景区停车场和校园开放式停车区域等场景。此类停车环境通常无固定监控探头、面积较大、车位分布分散，车辆进出频繁，且容易受到光照变化、阴影遮挡、雨雾天气、夜间低照度等因素影响，如图 2-1 所示。传统人工巡查方式效率较低，固定摄像头也存在安装成本高、覆盖盲区多、视角不灵活等问题，因此需要一种具备自主移动、主动观察和车牌识别能力的智能停车管理系统。

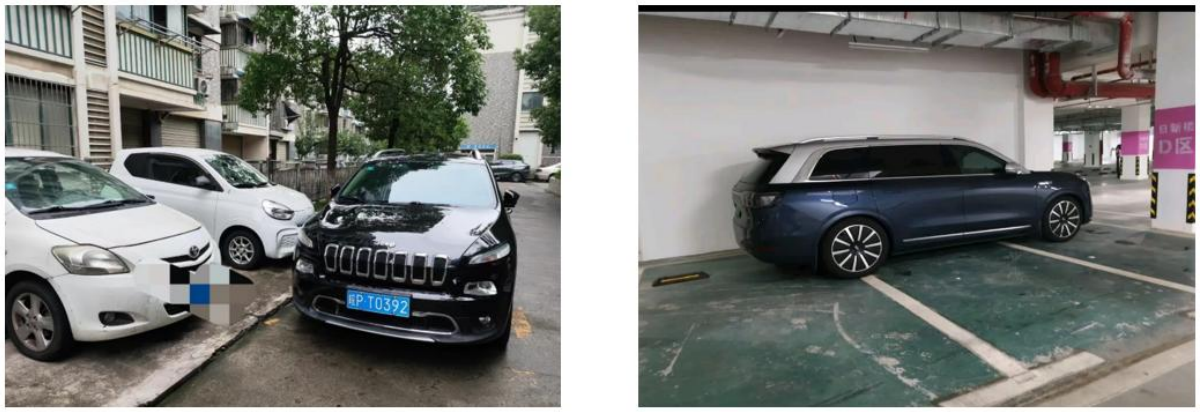


图 2-1　常见的违停场景（左图：室外，右图：室内）

在室外，系统以移动巡检小车为载体，由上位机根据环境地图、巡检路线和任务目标进行定位导航与路径规划，下位机负责底盘电机控制，使小车能够沿停车通道、车位区域和出入口附近自主行驶。GD32H759 负责摄像头图像采集、车牌检测识别和二轴云台控制，在巡检过程中实时获取车辆图像，并完成端侧 AI 推理。

当小车自主移动靠近停放车辆或经过出入口区域时，GD32H759 通过车牌检测模型定位车辆车牌区域，再调用车牌识别模型输出车牌号码。由于室外停车场中车辆角度变化较大，车辆可能停放不规范，摄像头与车牌之间也可能存在距离和角度偏差，系统通过二轴云台对目标车牌进行主动跟踪。当车牌目标偏离画面中心时，云台根据检测框位置自动调整俯仰角和偏航角，使车牌保持在较优观察位置，从而提升识别稳定性。

在巡检管理方面，系统可按照设定路线自动采集各车位车辆信息，记录车牌号码、车辆位置、识别时间和车位状态，并将结果上传停车管理平台。通过多次巡检，系统能够辅助完成车辆入场登记、车位占用统计、车辆查找、长时间停放车辆记录和异常占位识别等任务。对于大型室外停车场中固定摄像头难以覆盖的区域，移动巡检小车可以主动前往目标位置补充采集，提高整体管理覆盖率。

室外停车环境更加复杂，系统需要具备较好的环境适应能力。白天强光、夜间弱光、车身反光、阴影遮挡和天气变化都会影响图像质量，因此系统可结合云台主动调整视角，并通过模型优化和数据集扩充提高识别鲁棒性。后续还可扩展补光灯、毫米波雷达、超声波避障、GPS/北斗定位等模块，使系统更适合开放式停车区域的长期运行。

面向室外停车的应用中，本系统能够实现自主巡检、车牌识别、目标跟踪、车位信息采集和停车管理辅助等功能。通过 GD32H759 的端侧视觉识别与云台控制、上位机的导航规划以及下位机的底盘运动控制协同工作，可有效提升室外停车场管理的自动化程度和巡检效率。

2.2 系统功能需求分析

系统不是单一摄像头模块，也不是单独底盘控制板，而是由运动平台、视觉采集和二轴执行机构共同组成的嵌入式系统。方案设计优先考虑稳定性、实时性和可调试性，并在此基础上兼顾成本、体积和扩展能力。系统采用“主控集中协调、模块分区实现”的总体思路：GD32H759 负责接口管理和状态协调，底盘驱动、云台驱动和视觉采集作为相对独立的功能单元，系统需求与设计约束如表 2-1 所示。

表 2-1　系统需求与设计约束

需求类别	主要表现	对方案的影响	本设计取向
底盘运动控制	底盘启停、转向及急停	需要稳定通信和驱动接口	底盘采用 CAN 连接驱动器
摄像头视觉采集	车牌区域图像输入	要求摄像头接口具备一定带宽	采用 OV2640 并行接口方案
二轴云台执行	摄像头视角调整	要求电机低速平稳、抖动较小	采用 GB4310 无刷云台电机

雷达建图与路径规划	环境地图构建、定位	需要较强的计算能力	采用 RK3588 负责激光雷达建图、定位与路径规划
供电可靠	电机与摄像头共存	需要降低电源波动和干扰传导	采用分级供电与保护设计
系统调试	下载程序、观察状态	需要保留调试和扩展通道	设置 DAP、RS485 等接口

2.3 系统性能需求分析

本系统由 GD32H759、上位机、下位机底盘控制模块和二轴云台等部分组成，需要协同完成车牌识别、目标跟踪、定位导航和底盘运动控制等任务。系统运行效果不仅取决于单个模块的性能，也与各模块之间的数据交互和控制响应密切相关。因此，系统在设计时需要重点考虑实时性、识别准确性、云台跟踪稳定性、底盘运动可靠性、通信稳定性以及停车场环境适应能力。在实际停车场场景中，车辆和巡检小车可能处于运动状态，图像采集、AI 推理、云台控制和底盘执行之间如果存在明显延迟，会影响车牌识别和目标跟踪效果。因此，GD32H759 需要较稳定地完成图像采集、模型推理和云台控制，上位机也需要及时完成导航规划，并向下位机发送运动控制指令，保证小车能够按照任务要求完成巡检。

车牌检测与识别是系统的核心功能，其结果会直接影响车辆信息记录和后续管理判断。系统应能够在常见停车场环境下完成车牌区域定位和字符识别，并对识别结果进行置信度判断和多帧筛选，减少误识别和漏识别情况。对于光照变化、车牌角度偏斜、画面模糊等情况，系统需要具备一定的鲁棒性，保证识别结果具有可用性。

二轴云台主要用于提高目标观察和连续识别能力。系统根据车牌检测框位置计算目标中心与图像中心之间的偏差，并控制云台完成偏航和俯仰调整，使目标尽量保持在画面中心区域。云台运动过程应保持平稳，避免因频繁调整产生抖动，也要避免响应过慢导致目标脱离视野。

底盘运动控制关系到移动巡检过程的安全性和稳定性。下位机需要准确接收运动指令，并控制小车完成前进、后退、转向和停止等动作。RK3588 上位机根据停车场地图和巡检任务进行路径规划，使小车能够沿预定路线移动。在车辆停放变化、通道遮挡等情况下，

系统应具备一定的路径调整能力，以保证巡检任务能够顺利进行。

各模块之间的通信稳定性也是系统可靠运行的重要条件。GD32H759、上位机、下位机和二轴云台之间需要传输识别结果、控制指令、运动状态和异常信息，因此通信协议需要格式清晰、传输稳定，并具备基本的数据校验和异常恢复能力。通信异常时，系统应能够及时检测并采取相应处理措施，避免错误指令影响设备运行。由此可见，本系统的性能需求主要集中在图像采集与 AI 推理实时性、车牌识别准确性、云台跟踪稳定性、底盘运动可靠性、导航规划有效性、通信稳定性和复杂环境适应性等方面。具体性能需求归纳如表 2-2 所示。

表 2-2　系统需求分析

性能类别	主要需求	设计要求
图像采集实时性	摄像头图像应能够稳定采集和显示	保证图像输入连续，满足车牌检测与现场调试需求
AI 推理实时性	GD32H759 端完成车牌检测与识别推理	推理延迟应满足低速巡检场景下的实时识别需求
识别准确性	能够完成车牌区域检测和字符识别	对识别结果进行置信度判断和多帧过滤，降低误识别
云台跟踪性能	根据目标偏差控制偏航轴和俯仰轴	目标应尽量保持在画面中心附近，云台运动平稳
底盘控制性能	下位机执行前进、后退、转向、停止等动作	控制响应及时，运动过程平稳，能够接收停止指令
导航规划性能	RK3588 完成定位、路径规划和任务调度	能够根据巡检路线规划运动路径，并支持路径更新
通信可靠性	GD32H759、上位机、下位机和云台之间稳定通信	指令格式规范，具备校验、反馈和异常恢复机制

系统稳定性	系统能够持续运行并处理异常状态	支持摄像头恢复、CAN 状态检测、通信异常处理等功能
环境适应性	适应停车场光照、遮挡、车辆密集等复杂情况	通过图像预处理、结果过滤和运动控制优化提高鲁棒性

3 系统架构设计

3.1 系统功能架构

本系统采用分层协同的功能架构，如图 3-1 所示，整体由模型推理与显示板、ESP32 通信板、电机控制板、RK3588 导航模块和底盘驱动模块组成。各模块按照“视觉感知—模型推理—目标跟踪—导航规划—运动执行—状态反馈”的流程协同工作，实现停车场环境下的车牌识别、二轴云台跟踪和移动巡检管理。

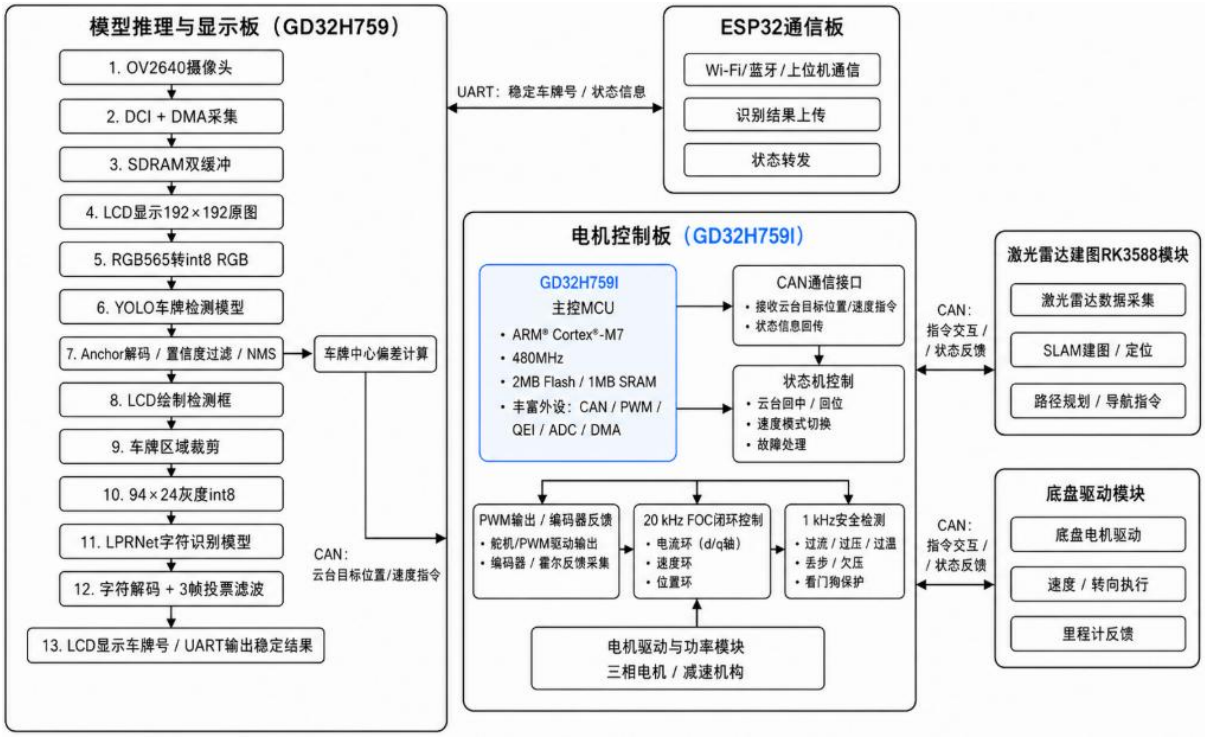


图 3-1　系统需求分析

模型推理与显示板以 GD32H759 为核心，主要承担图像采集、AI 模型推理和识别结果显示功能。系统通过 OV2640 摄像头采集停车场环境图像，并利用 DCI 接口和 DMA 方式完成图像数据读取。采集到的图像经过 SDRAM 双缓冲处理后，一方面送入 LCD 屏进行实时显示，另一方面转换为模型输入所需的数据格式。系统先利用 YOLO 车牌检测模型定位图像中的车牌区域，再对车牌区域进行裁剪、灰度化和尺寸归一化处理，随后送入 LPRNet 字符识别模型完成车牌号码识别。识别结果经过字符解码和多帧投票滤波后，可在 LCD 屏上显示，也可通过通信模块上传至上位机。

二轴云台跟踪功能同样依赖模型推理结果实现。GD32H759 根据车牌检测框的位置计算目标中心点与图像中心点之间的偏差，并将该偏差转换为云台偏航轴和俯仰轴的控制量。随后系统通过 CAN 通信向电机控制板发送云台目标位置或速度指令，使云台能够根据车辆位置变化自动调整摄像头方向，将目标车牌尽量保持在画面中心区域，从而提高连续识别的稳定性。

ESP32 通信板主要用于系统识别结果和运行状态的无线传输。该模块通过 UART 与模型推理板进行数据交互，接收稳定车牌号、识别状态和系统运行信息，并通过 Wi-Fi、蓝牙或上位机通信方式完成数据上传。该设计便于后续接入停车场管理平台，实现车辆信息记录、远程监测和运行状态查看。

电机控制板以 GD32H759 主控 MCU 为核心，主要完成二轴云台电机控制、状态机管理和底盘相关控制指令转发。该模块通过 CAN 接口接收模型推理板发送的云台控制指令，并结合电机反馈信息完成闭环控制。电机控制部分包括 PWM 输出、编码器反馈、位置/速度控制、安全检测和状态管理等功能。其中，PWM 与编码器反馈用于实现电机驱动和位置检测，FOC 闭环控制用于提高云台或电机运行的平稳性，安全检测模块用于监测过流、堵转、丢步和看门狗等异常情况，保证系统运行可靠。

RK3588 模块作为上位机，主要负责停车场环境下的激光雷达数据采集、SLAM 建图定位以及路径规划与导航指令生成。系统通过激光雷达获取周围环境信息，并结合 SLAM 算法完成小车定位和地图构建[4]。在巡检任务执行过程中，RK3588 根据停车场地图和目标任务点生成导航路径，并通过 CAN 通信向电机控制板或底盘控制模块发送运动指令，使小车能够按照规划路线完成自主移动。

底盘驱动模块负责小车底盘电机的实际驱动和运动执行。该模块接收来自控制板的速度和转向指令，驱动底盘电机完成前进、后退、转向和停止等动作，并将里程计、速度和转向状态反馈给上位机或控制板。通过底盘状态反馈，RK3588 能够对小车位置和运动状态进行持续更新，从而提高导航控制的稳定性。

整体来看，本系统采用模块化与分层协同的总体设计思路，将 AI 推理、云台控制、无线通信、导航规划和底盘执行等功能分别部署于不同功能单元中。其中，模型推理板主要承担图像采集、车牌检测与字符识别任务；电机控制板负责云台电机闭环控制与目标跟踪执行；RK3588 上位机承担环境感知、定位导航、路径规划和任务调度功能；底盘驱动模块则根据上位机控制指令完成移动平台的运动执行。该架构能够有效降低各功能模块之间的耦合度，提高系统调试、维护和功能扩展的灵活性。同时，模块化设计也便于后续对

车牌识别模型、云台控制算法、导航规划策略和底盘机械结构进行独立优化，为停车场智能巡检、车辆信息采集、违停识别及多场景扩展应用提供了良好的系统基础。

3.2 系统硬件架构

本小节主要介绍系统硬件总体设计方案，以 GD32H759 为核心控制器，构建包括底盘驱动、二轴云台控制、视觉采集及电源管理在内的嵌入式硬件系统。整体设计采用分区供电与隔离的思路，通过多级电源转换与保护电路提升系统稳定性；同时结合 CAN、RS485 及调试接口实现底层驱动与系统扩展。各功能模块协同工作，共同构成稳定可靠的硬件平台，为后续运动控制与视觉识别功能提供基础支撑。

3.2.1 底盘原理分析

如图 3-2 所示，系统整体架构以 GD32H759 核心控制器为中心，按照电源输入与保护、电源转换与监测、核心控制、传感器与接口、外部执行与上位机通信等功能进行模块化设计。电源部分采用 35V 直流输入，经 DC 充电电路、保险丝、保护电路、TVS 静电防护及防反接保护后进入后级电源转换模块，并通过 TPS54560DDA 和 RT9013-3V3 分别生成 5V 和 3.3V 电源，为主控、传感器和通信接口提供稳定供电。同时，系统设置工作温度监测、过流/过压/欠压保护及 MOS 切换断电保护，主控可根据 Vin、Iin 和温度等状态信息进行安全判断。

在控制与通信方面，GD32H759 负责协调各功能模块的运行。右侧传感器与接口模块包括红外测距、超声波测距、IMU 姿态采集、CAN 总线、RS485 总线、按键电路和调试接口，用于实现环境感知、姿态获取、底盘通信、外设扩展和程序调试。系统通过 LoRa 接收机获取速度、转向和急停等控制指令，并与 LoRa 发射机形成无线控制链路。外部执行部分通过 CAN 总线连接上位机、伺服电机转速控制模块和编码器，实现底盘运动控制与速度反馈。整体设计采用分级供电、集中控制和多接口扩展的方式，提高了系统运行的稳定性、可靠性和可维护性。

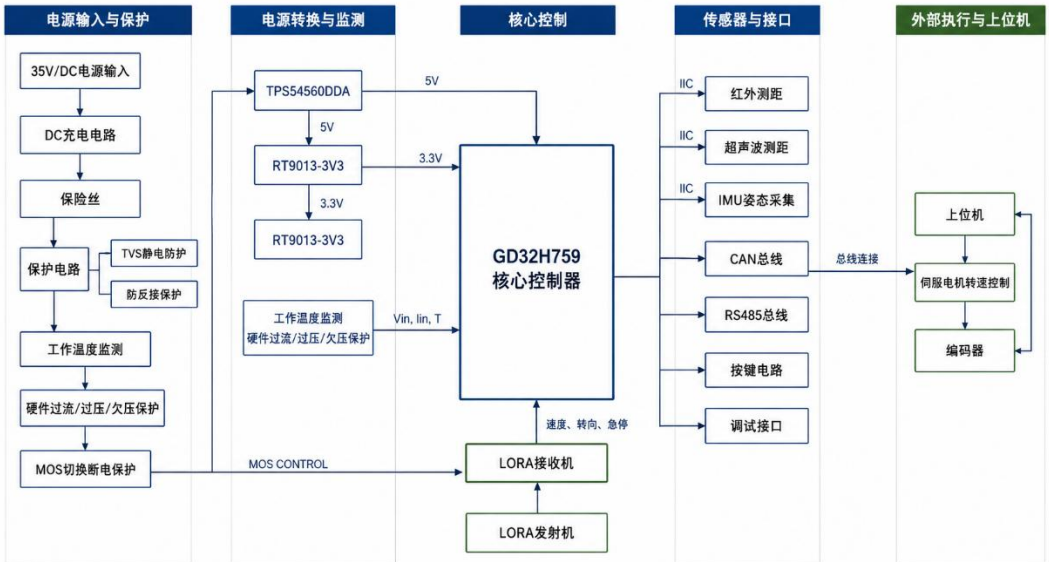


图 3-2　底盘硬件结构图

3.2.2　二轴云台电机驱动及相机原理分析

本系统二轴云台采用俯仰（Pitch）与航向（Yaw）双自由度结构，用于实现摄像头视场的稳定指向与机械角度调整。执行电机选用 GB4310 无刷直流云台电机，该电机具有低齿槽转矩、高动态响应及低速运行平稳等特点，适用于对抖动敏感的视觉采集系统。

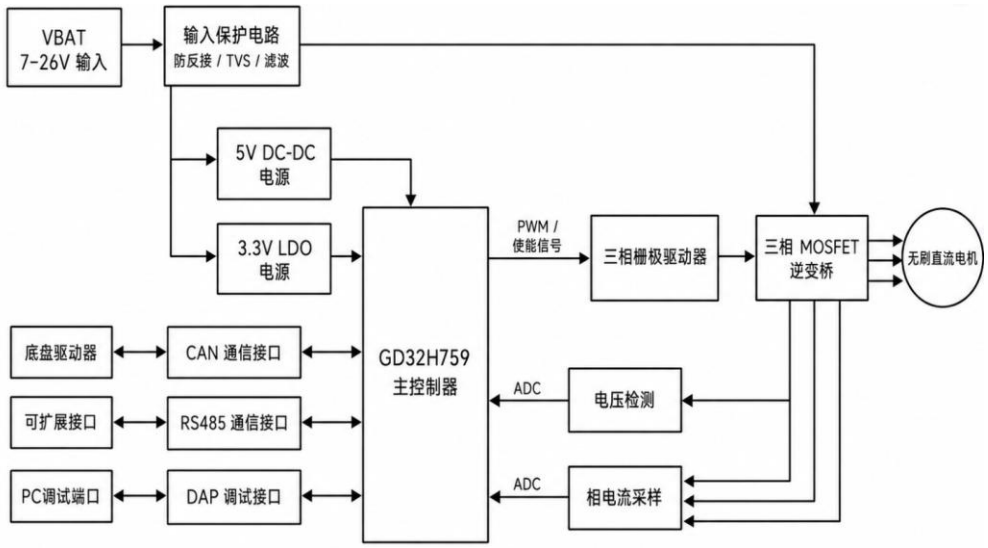


图 3-3　二轴云台电机驱动系统框架

电机驱动部分采用 DRV8300D 三相栅极驱动器与外置功率 MOSFET 组成的三相全桥驱动结构[5]，如图 3-3 所示。其中，DRV8300D 负责提供三相半桥栅极驱动信号及死区控制功能，实现对高低侧 MOSFET 的同步驱动；功率级采用 AON7544 N 沟道 MOSFET 构建三相逆变桥，用于完成电能到三相交流驱动信号的转换，从而驱动 GB4310 无刷电机运转。该结构具有驱动能力强、导通损耗低及散热性能良好的特点，适用于中小功率云台应用场景。

在反馈检测方面，系统通过电压检测和相电流采样电路将母线电压及电机相电流送入主控 ADC 接口，为电机运行状态监测和闭环控制提供基础数据。通信与调试部分包括 CAN 通信接口、RS485 通信接口和 DAP 调试接口，其中 CAN 接口用于连接底盘驱动器，RS485 作为外部扩展接口，DAP 接口用于 PC 端程序下载与在线调试。整体设计实现了电源管理、功率驱动、状态采样和通信调试的集成，为无刷直流电机稳定运行提供了硬件基础。

3.2.3 相机与 LCD 原理分析

OV2640 是一款常用的 CMOS 图像传感器，其工作过程主要包括光电转换、图像处理和数字信号输出。外界光线经过镜头进入感光阵列后，传感器将光信号转换为电信号，并在芯片内部完成曝光控制、增益调节、白平衡、色彩处理等基本图像处理。GD32H759 通过 SCCB 接口对 OV2640 进行初始化配置，设置图像分辨率、输出格式、采集窗口和工作模式等参数，使摄像头能够按照系统需求输出稳定的图像数据。

在图像读取过程中，OV2640 通过 D0～D7 并行数据线输出图像像素数据，并通过 PCLK、VSYNC 和 HREF 等同步信号确定像素、帧和行的有效时序。GD32H759 利用数字摄像头接口对这些信号进行同步采集，并通过 DMA 将图像数据自动搬运到 SDRAM 帧缓冲区，减少 CPU 直接搬运数据的负担。当摄像头配置为 RGB565 格式时，采集到的数据可直接用于 LCD 显示，系统只需将帧缓冲区中的图像数据送入 LCD 驱动进行刷新，即可实现摄像头画面的实时显示。整体流程为：OV2640 采集图像、GD32 同步接收、DMA 缓存数据、LCD 刷新显示。

3.3 系统软件架构

本系统软件采用分层式架构设计如图 3-4 所示，自下而上包括硬件层、BSP 层、驱动层、中间件/组件层、算法层/业务逻辑层和应用层。硬件层由 OV2640 摄像头、RGB LCD、SDRAM、GD32H759 主控板、电机控制板、ESP32 通信板及云台机构组成，为图像采集、结果显示、数据存储、运动控制和无线通信提供基础。BSP 层负责时钟、GPIO、中断、外设初始化和引脚复用配置，为上层驱动提供板级支持。驱动层封装 DCI、DMA、LCD、UART、CAN、SDRAM、摄像头及 PWM/ADC/编码器等外设驱动，实现对硬件资源的直接调用。中间件/组件层完成图像缓存、RGB565 格式转换、GD NN Runtime 模型推理、LCD 绘图、串口协议、CAN 通信和静态内存管理等功能，起到底层驱动与上层算法之间的衔接作用。算法层主要完成 YOLO 车牌检测、Anchor 解码、NMS、LPRNet 字符识别、三帧投票滤波、云台偏差计算及电机闭环控制等任务。应用层则负责摄像头采集显示、车牌检测识别、结果显示、串口输出和云台跟踪等功能调度。该架构使各模块职责清晰，便于软件调试、功能扩展和系统协同运行。

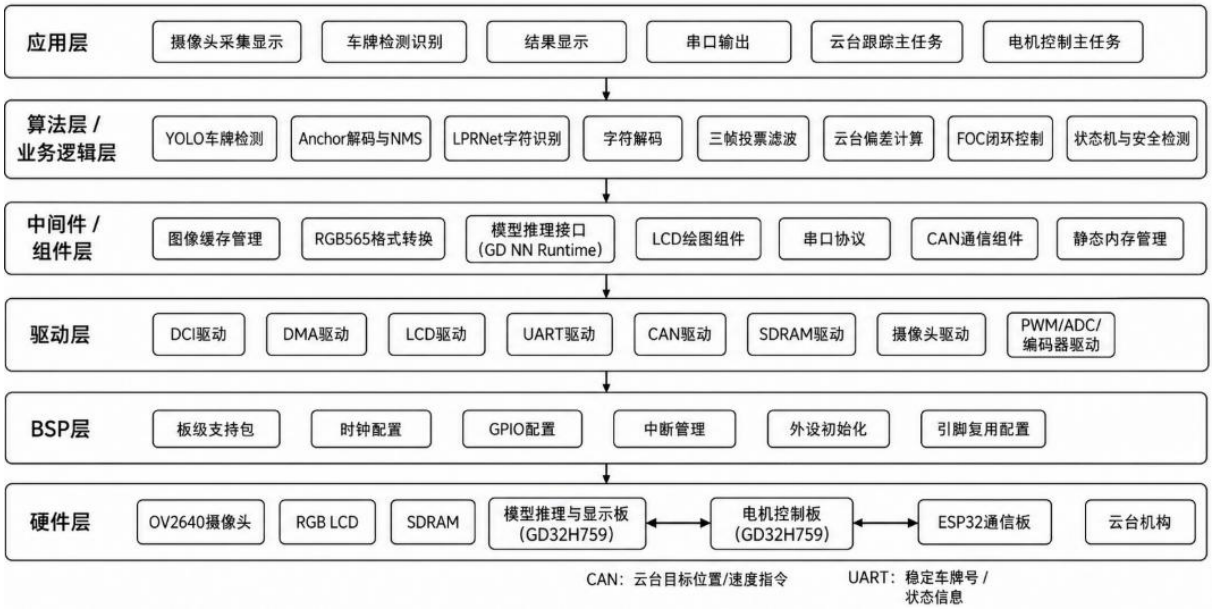


图 3-4 系统软件分层架构

本系统软件运行于 GD32H759I Cortex-M7 微控制器平台，采用裸机前后台式软件架构。系统以主循环轮询作为主要任务调度方式，以 SysTick 提供毫秒级时间基准，并通过 DCI、DMA、EXMC、LCD、USART、CAN 等片上外设完成图像采集、数据显示、通信交互和云台控制等功能。AI 推理部分基于 GD NN Runtime 部署车牌检测模型和字符识

别模型，使系统能够在端侧完成图像采集、车牌定位、字符识别、结果显示和云台跟踪等闭环处理。

软件启动后，系统首先完成基础运行环境初始化，包括中断向量表、MPU、Cache、SysTick 和延时服务等配置；随后依次初始化外部 SDRAM、RGB LCD、摄像头接口、识别结果串口和 CAN 云台控制接口；在硬件资源准备完成后，完成车牌检测模型和字符识别模型的参数绑定与运行时初始化。系统进入主循环后，持续轮询摄像头帧状态和云台指令发送状态。当 DCI 与 DMA 完成一帧图像采集后，系统调用视觉处理流程，对当前图像进行单帧推理、结果解析和控制输出。

在整体处理链路上，摄像头首先采集 RGB565 格式图像，系统将其转换为模型输入所需的数据格式；随后由 YOLO 车牌检测模型输出候选车牌框，后处理模块完成 Anchor 解码、置信度阈值过滤和 NMS 非极大值抑制，获得最终车牌区域。系统再根据检测框裁剪车牌图像，并完成缩放、灰度化和量化处理，生成 LPRNet 字符识别模型输入。字符识别模型输出 7 位字符分类结果后，系统对识别结果进行格式校验和多帧投票滤波，并通过 LCD、UART 和 CAN 等接口完成结果显示、数据上传和云台控制。

在运行调度方面，系统采用裸机轮询方式组织任务流程。图像搬运等数据量较大的操作由 DMA 完成，降低 CPU 负担；摄像头采集状态通过主循环进行检测；AI 推理在图像帧就绪后同步执行；云台控制命令则在主循环中按照发送状态分步下发。该方式结构简单、执行流程清晰，能够满足本系统端侧识别与实时控制的需求。

在内存组织方面，系统主要采用静态缓冲区管理模型输入、模型输出和中间计算数据。车牌检测模型和字符识别模型共用 static_buffer_peak 等静态内存池，以减少动态内存分配带来的不确定性。摄像头帧缓冲区放置在外部 SDRAM 中，并划分为 DMA 可访问区域，保证图像采集和数据搬运过程的稳定性。

在可靠性设计方面，摄像头模块记录 DMA 剩余计数、DCI 工作状态、溢出次数和帧停滞次数等调试信息，用于判断图像采集链路是否异常。当系统长时间未获取新帧，或出现 DMA 错误、DCI 溢出等情况时，软件会执行 dci_restart() 或摄像头硬件恢复流程，以提高系统连续运行的稳定性。整体来看，该软件架构在保证功能实现的同时，兼顾了端侧 AI 推理、图像采集、云台控制和异常恢复等需求。

3.4系统可扩展性设计

基于 GD32H759 的二轴云台停车智能管理系统面向停车场车辆识别、目标跟踪、移动巡检与智能管理等应用需求。由于停车场环境具有车辆流动性强、光照条件复杂、管理任务多样等特点，系统在设计过程中不仅需要满足当前车辆识别与云台追踪功能，还需要考虑后续功能扩展、算法升级和多设备协同应用。因此，本文从硬件架构、软件模块、算法模型、数据资源和应用场景等方面对系统可扩展性进行设计，使系统能够在不改变主体架构的前提下实现功能拓展和性能提升。

3.4.1 硬件可扩展性

在硬件结构上，系统采用“上位机、核心控制单元、下位机执行模块”相结合的分层设计方式。其中，RK3588 上位机主要负责停车场环境定位、路径规划和导航决策；GD32H759 作为系统的核心边缘控制单元，负责 AI 模型推理、目标识别结果处理以及二轴云台的位置追踪控制；下位机模块主要完成小车底盘电机驱动、速度控制和运动执行。

这种分层硬件结构具有较好的扩展性。GD32H759 并不直接承担全部系统任务，而是集中处理与实时识别、云台控制和边缘推理相关的核心功能，降低了单一控制器的负载压力。当系统后续需要增加新的硬件设备时，例如超声波避障模块、激光雷达、深度相机、补光灯、环境传感器或报警装置，可以通过预留通信接口接入系统，不需要对整体架构进行大规模修改。

同时，下位机模块独立承担底盘电机控制任务，可以根据不同停车场巡检平台的需求更换电机类型、驱动模块或底盘结构。例如，当系统由小型实验平台扩展到实际停车场巡检小车时，只需针对底盘动力系统和电机控制参数进行调整，而不需要改变 GD32H759 的视觉识别和云台追踪逻辑。RK3588 上位机也可根据实际需求扩展更高精度的定位传感器或地图构建模块，从而提升系统在复杂停车场环境中的导航能力。

执行机构方面，当前系统已通过 CAN 总线对云台俯仰轴和偏航轴进行节点化控制，云台电机节点 ID、跟踪增益、死区范围和最大转角等参数均采用宏定义配置，便于更换不同型号电机或扩展多自由度云台。同时，下位机底盘控制模块可继续扩展为差速轮、麦克纳姆轮或舵轮底盘，只需保持与 GD32H759 的通信协议一致，即可完成控制层替换。因此，本系统在传感器、执行机构和边缘计算设备三个方面均具备较强硬件可扩展性。

3.4.2 软件功能模块可扩展性

在软件设计方面，系统按照功能解耦的原则进行模块化划分，主要包括图像采集模块、AI 推理模块、云台控制模块、通信模块、底盘控制模块、定位导航模块和任务管理模块。各模块之间通过统一的数据格式和通信协议进行信息传递，使不同功能之间保持相对独立。

GD32H759 端的软件主要围绕 AI 模型推理和云台位置追踪展开。图像采集模块负责获取停车场环境图像，AI 推理模块完成车辆、车牌、车位或目标对象的识别，云台控制模块根据识别结果调整二轴云台的水平角度和俯仰角度，实现对目标的持续跟踪。由于这些模块之间采用清晰的数据输入与输出关系，因此后续如果需要增加新的识别任务，例如行人检测、异常停车检测、占道识别或车位状态识别，可以在原有 AI 推理模块基础上扩展模型类别，而不会影响底盘控制和导航规划功能。

上位机主要负责定位、建图、路径规划和全局任务调度。其软件模块可以根据停车场环境复杂程度进行扩展，例如增加自主巡检路径规划、动态避障、电子地图管理或多车协同调度功能。下位机模块则主要负责电机控制、速度反馈和运动执行，当底盘结构或运动方式变化时，只需修改下位机控制程序和运动参数，上层导航与云台识别模块仍可保持稳定运行。通过这种模块化软件结构，系统能够较好地支持后续功能增加和平台升级。

这种设计方式有利于后续功能扩展。若需要扩展新的数据采集模块，只需增加对应传感器驱动和数据接口；若需要修改预处理流程，可在图像格式转换、裁剪、灰度化或归一化模块中单独调整；若需要更换模型推理流程，可通过统一的 nn_model 结构体进行模型初始化与调用；若需要与 RK3588 或下位机交互，也可以在 UART、CAN 或其他通信协议层新增消息封装。软件结构将数据采集、预处理、模型推理、结果后处理、执行控制和外部通信分开实现，便于系统在复杂停车场场景中持续迭代。

3.4.3 算法模型可扩展性

在算法层面，系统将 AI 模型推理与云台追踪控制部署在 GD32H759 端，使其能够在边缘侧完成目标识别和实时响应。由于停车场智能管理任务可能随着应用需求变化而不断增加，系统在算法设计中预留了模型替换与升级机制。

当前系统可以围绕车辆检测、目标识别或车位状态判断等任务进行模型部署。当后续需要提高识别精度或增加识别类别时，可以通过重新训练模型、优化模型结构或进行模型

压缩的方式完成算法升级。例如，在停车场入口管理场景中，可重点优化车辆和车牌识别模型；在巡检管理场景中，可扩展车位占用状态识别、违停车辆识别和行人检测模型；在夜间或弱光环境下，还可以结合图像增强算法或红外传感数据，提高系统对复杂环境的适应能力。

当前系统在 GD32H759 端部署了两个 int8 量化模型：车牌检测模型 yolo_keras_int8 和车牌字符识别模型 lprnet_tiny_int8。其中，YOLO 模型用于从摄像头图像中检测车牌区域，LPRNet 模型用于对裁剪后的车牌区域进行字符识别。代码中模型输入、输出缓存、算子回调数组和模型参数均采用独立结构配置，因此在保持输入输出接口一致的情况下，可以较方便地替换新的检测模型或识别模型。在后续升级中，可根据实际需求引入更轻量化的检测网络、更高精度的车牌识别模型，或扩展车辆类型识别、车位占用检测、行人检测、异常停车检测等模型。模型也可以通过剪枝、量化感知训练、蒸馏和算子融合等方式进一步压缩，以适配 GD32H759 的片上资源和实时性要求。对于 RK3588 上位机，也可以部署更复杂的多目标跟踪、语义地图构建和路径规划算法，与 GD32H759 的端侧识别结果形成协同。因此，系统在模型替换、模型压缩、模型升级和重新训练方面具有良好的算法扩展能力。

云台追踪算法也具有一定的扩展空间。当前系统可根据目标在图像中的位置偏差控制二轴云台转动，使目标保持在视野中心区域。后续可进一步引入 PID 控制优化、目标运动预测或多目标选择策略，提高云台跟踪的稳定性和响应速度。RK3588 端的定位导航算法同样可以根据实际环境进行升级，例如由基础路径规划扩展到动态避障、多点巡航和自主回充等功能，从而提升系统整体智能化水平。

3.4.4 数据层可扩展性

系统的数据资源同样具备持续扩展能力。当前代码中已经包含车牌检测框、识别字符、置信度、裁剪区域、灰度图统计量、滤波结果和 CAN 输出等调试与结果变量，便于在实际运行中记录识别过程和错误样本。后续可结合 RK3588 的定位与任务管理能力，将图像帧、车牌裁剪图、识别结果、车辆位置、时间戳和场景标签统一保存，形成停车场专用数据集。

随着系统部署范围扩大，数据集可以持续补充白天、夜间、逆光、雨雾、遮挡、车牌污损、多车并行、不同省份车牌和新能源车牌等样本，从而提升模型对复杂环境的泛化能力。标注体系也可以从单一车牌框和车牌字符扩展到车位编号、车辆类别、车位占用状态、

障碍物类别、行人区域和巡检异常类型。通过“现场采集、样本筛选、人工标注、模型训练、端侧部署、在线验证”的闭环流程，系统能够不断积累数据资源并提高识别精度。

3.4.5 应用场景可扩展性

本系统虽然以停车智能管理为主要应用场景，但其系统架构具有较强迁移能力。在停车场内部，系统可扩展为车位引导、车牌识别入场、车辆寻车、异常停车提醒、巡检录像和无人值守收费等功能。GD32H759 可负责实时视觉感知与云台目标跟踪，RK3588 则负责路径规划、地图管理和任务调度，下位机负责稳定执行运动控制。

在其他场景中，该系统也可迁移到导览、接待、巡检等服务任务。例如，在导览场景中，系统可通过视觉识别车辆或人员位置，并结合 RK3588 的导航能力完成路径引导；在接待场景中，可根据车牌或预约信息完成身份核验和车辆引导；在巡检场景中，可通过云台主动观察重点区域，识别占道停车、障碍物、设备异常或安全隐患。由于核心感知、控制和规划模块相互独立，系统只需调整任务逻辑和模型数据集，即可从停车场管理扩展到更广泛的智能移动机器人服务场景。

4 数据集方案

本章主要介绍车牌检测与识别模型的数据集方案。围绕停车场智能巡检系统的应用需求，本文选取 CCPD2019 和 CCPD2020 作为模型训练与验证的数据来源，其中 CCPD2019 以普通蓝牌为主，覆盖普通、模糊、旋转、倾斜、远距离、暗光等多种停车场成像场景，CCPD2020 则补充新能源绿牌样本，为模型适配不同车牌颜色和字符长度提供数据基础。在数据处理方面，本文根据“先检测、后识别”的两阶段流程，分别构建 YOLO 检测模型和 LPRNet 识别模型的数据预处理方法，包括文件名标签解析、图像缩放、letterbox 填充、车牌区域裁剪、灰度化、尺寸统一和量化输入转换等步骤。同时，针对蓝牌与绿牌样本分布不均衡、字符位数不同等问题，进一步开展数据分布分析和分层划分设计，为后续模型训练、性能验证和端侧部署提供规范、稳定的数据基础。

4.1数据来源

本项目采用 CCPD（Chinese City Parking Dataset）公开数据集作为车牌检测与识别模型的训练数据来源。该数据集由中国科学技术大学相关研究团队提出，并用于 ECCV 2018 论文《Towards End-to-End License Plate Detection and Recognition: A Large Dataset and Baseline》。CCPD 面向中国城市停车场真实场景采集，图像格式为 JPEG，标注信息直接编码在文件名中，包括车牌号、车牌边界框、四个顶点坐标、倾斜角度、亮度和模糊程度等内容，可同时支持车牌检测、角点定位和字符识别任务。

在数据使用方面，本文联合采用 CCPD2019 与 CCPD2020 数据。其中，CCPD2019 主要包含普通中国车牌图像，以蓝牌为主，覆盖普通、模糊、旋转、倾斜、远距离、暗光和复杂退化等多种停车场成像条件；CCPD2020 又称 CCPD-Green，主要包含新能源绿色车牌图像，车牌号码通常为 8 位字符。因此，两类数据集联合训练能够扩展模型对普通蓝牌和新能源绿牌的覆盖范围，使检测模型同时学习不同颜色、不同长度车牌的外观特征，也为识别模型适配 7 位普通车牌和 8 位新能源车牌提供数据基础。

CCPD 数据集采用开源方式发布，原始项目页面提供数据下载链接、划分方式及论文引用说明，项目代码和数据说明遵循 MIT License。本文仅将该数据集用于学术研究和竞赛验证，不涉及商业用途。根据原始论文与公开仓库说明，CCPD 原始数据规模超过 25 万张，2019 更新版本进一步扩展到 30 万张以上；实际实验中，以下载、清洗和格式转换

后的有效样本数量为准。

与 COCO、VOC 等通用目标检测数据集相比，CCPD 的优势在于任务场景与本项目高度一致。COCO 和 VOC 虽然覆盖目标类别丰富，但并非专门面向中国车牌识别任务，缺少车牌字符、四角点和中国车牌规则等标注信息。CCPD 直接来源于中国城市停车场场景，能够较好模拟本项目中“移动平台进入停车区域后进行车牌采集与识别”的应用环境。同时，CCPD2019 提供多种复杂子场景，CCPD2020 补充新能源车牌样本，使训练数据能够覆盖停车场中常见的普通蓝牌与新能源绿牌目标。

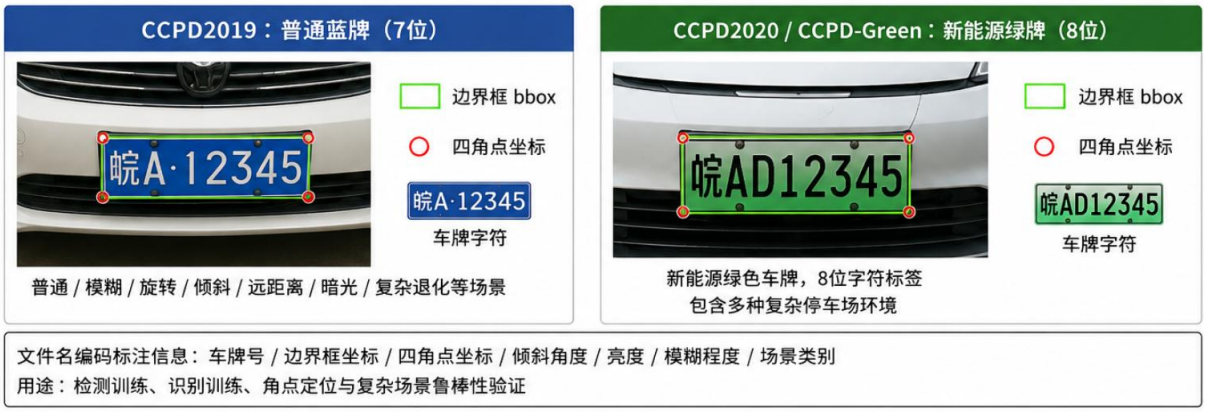


图 4-1　CCPD 数据集样本及标注信息示意图

表 4-1　数据集基本信息

项目	说明
数据集名称	CCPD2019 与 CCPD2020 / CCPD-Green
数据来源	中国科学技术大学相关研究团队公开数据集
发表论文	Xu 等，Towards End-to-End License Plate Detection and Recognition: A Large Dataset and Baseline，ECCV 2018
许可协议	MIT License；本文仅用于学术研究和竞赛验证
数据规模	原始 CCPD 超过 25 万张；CCPD2019 更新版本超过 30 万张，实际训练规模以清洗后样本为准
数据格式	JPEG 图像，标注信息编码于文件名
标注内容	车牌号、边界框、四角点坐标、倾斜角度、亮度、模糊程度等

数据类别	CCPD2019 以普通蓝牌为主；CCPD2020 / CCPD-Green 为新能源绿牌
场景覆盖	普通、模糊、旋转、倾斜、远距离、暗光、雨雪天气和复杂退化场景
与本项目匹配度	高。数据来源于中国停车场场景，车牌类型和应用环境与停车场智能管理任务一致

由图 4-1 和表 4-1 可见，CCPD 数据的核心优势在于图像样本、车牌位置和字符标签之间具有明确对应关系。普通蓝牌样本可用于 7 位车牌检测与识别训练，新能源绿牌样本可用于 8 位车牌识别扩展；同时，文件名中的边界框、角点和成像条件信息能够支持模型在倾斜、模糊、远距离等复杂场景下进行鲁棒性训练。

综上，本文选择 CCPD2019 与 CCPD2020 联合作为训练数据来源，主要基于三点考虑：第一，数据集来源于真实中国停车场场景，与本项目应用对象一致；第二，数据标注信息较完整，能够同时支持检测模型和识别模型训练；第三，联合使用普通蓝牌和新能源绿牌数据，可提高模型对不同车牌类型的适应能力。需要注意的是，由于普通蓝牌通常为 7 位字符，而新能源车牌通常为 8 位字符，后续识别模型需在输出维度和解码规则上进行相应适配。

4.2数据预处理

为保证车牌检测与识别模型能够稳定训练，并满足后续 GD32 端部署需求，本文对 CCPD 数据集进行了统一的数据预处理。由于系统采用“先检测、后识别”的两阶段识别流程，数据预处理也分为 YOLO 检测模型预处理和 LPRNet 识别模型预处理两条路径。前者重点保证车牌目标在缩放过程中的几何一致性，后者重点保证裁剪后车牌字符区域的完整性和输入尺寸统一性。

在 YOLO 检测模型预处理阶段，首先从 CCPD 图像文件名中解析车牌标注信息，主要包括车牌边界框坐标、四角点坐标和车牌字符标签。由于 CCPD 数据集将标注信息编码在文件名中，因此无需额外标注文件即可完成标签解析。随后，原始图像采用 letterbox 方式缩放至 192×192 输入尺寸，即在保持原始宽高比的基础上进行等比例缩放，并对空白区域进行填充。该方法能够避免直接拉伸图像造成车牌形变，更适合车牌这类小目标检

测任务。

整体预处理流程如图 4-2 所示，像素处理方面，训练阶段将图像像素由[0,255]归一化至[0,1]，以适配浮点模型训练；部署阶段则按 pixel-128 方式将 uint8 像素转换为 int8 输入，使输入格式与 MCU 端 INT8 量化推理保持一致。为提升模型对不同拍摄条件的适应能力，训练阶段加入 Mosaic 拼接、随机翻转、HSV 颜色扰动和尺度抖动等数据增强方式。其中，Mosaic 增强能够增加小目标上下文信息，对远距离、小尺度或复杂背景下的车牌检测具有一定帮助。

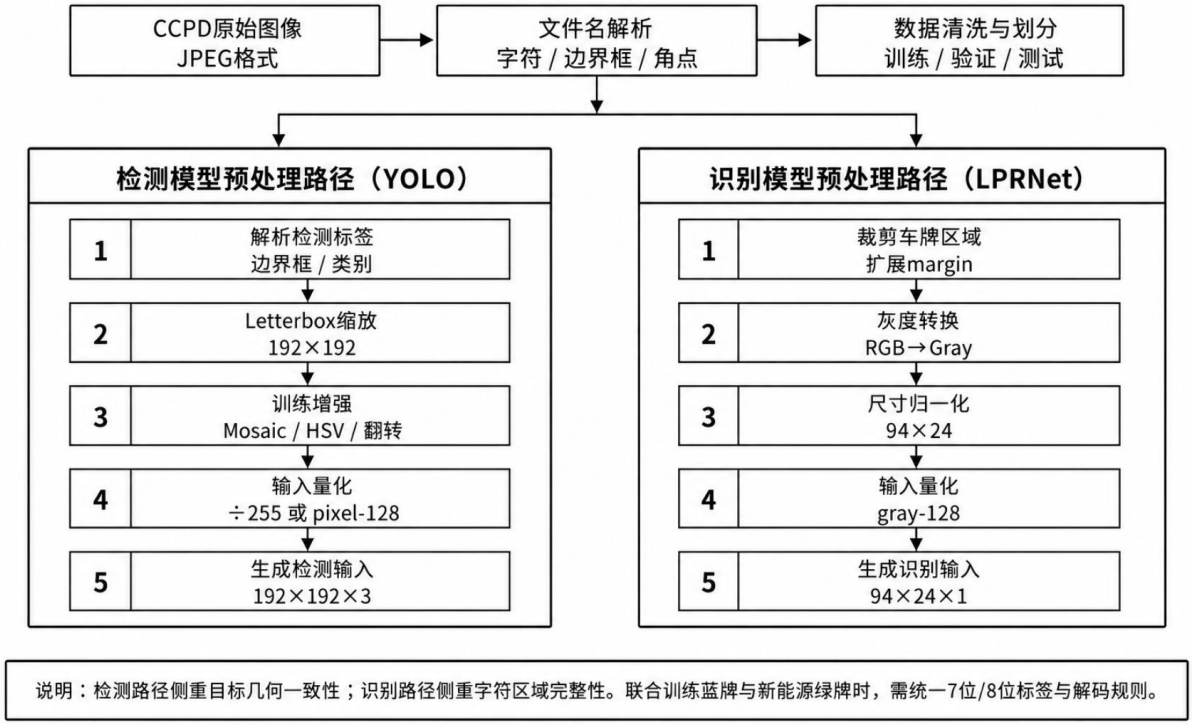


图 4-2　数据预处理示意图

在 LPRNet 识别模型预处理阶段，根据车牌检测框从原图中裁剪车牌区域，并在边界框四周适当扩展 margin，以保留车牌边缘字符笔画和局部上下文信息。裁剪后的车牌图像转换为灰度图，并统一缩放至 94×24（宽×高），作为 LPRNet Tiny 的输入。该尺寸在字符细节保留和端侧计算量之间取得较好平衡，适合资源受限的 MCU 端识别任务。识别模型输入同样采用 uint8 到 int8 的量化格式，使检测模型和识别模型在端侧具有统一的数据输入逻辑。

对于 CCPD2019 与 CCPD2020 联合训练的情况，本文在标签处理阶段同时考虑普通

蓝牌与新能源绿牌的差异。普通蓝牌通常为 7 位字符，而新能源车牌通常为 8 位字符，因此在识别模型训练前需要对车牌长度、字符集和解码规则进行统一整理。检测模型可直接合并两类车牌图像进行训练，以增强模型对不同颜色和不同尺寸车牌的检出能力；识别模型则需要根据最终输出结构选择 7 位、8 位或可变长度标签格式，以保证蓝牌和新能源绿牌均能被正确识别。

4.3数据分布分析

为保证车牌检测与识别模型训练的有效性，本文对 CCPD2019 与 CCPD2020 联合数据集的样本分布进行了统计分析，并从类别分布、数据均衡性以及数据集划分三个方面进行说明。

在类别分布方面，数据主要包括普通蓝牌与新能源绿牌两类。其中，普通蓝牌样本占比最高，覆盖 7 位字符车牌，包含普通清晰、模糊、遮挡、旋转、远距离及复杂光照等多种场景；新能源绿牌样本占比相对较低，车牌字符长度为 8 位，主要用于扩展模型对新能源车辆的识别能力。从整体分布来看，蓝牌样本数量明显高于绿牌样本，数据呈现一定不均衡特性。

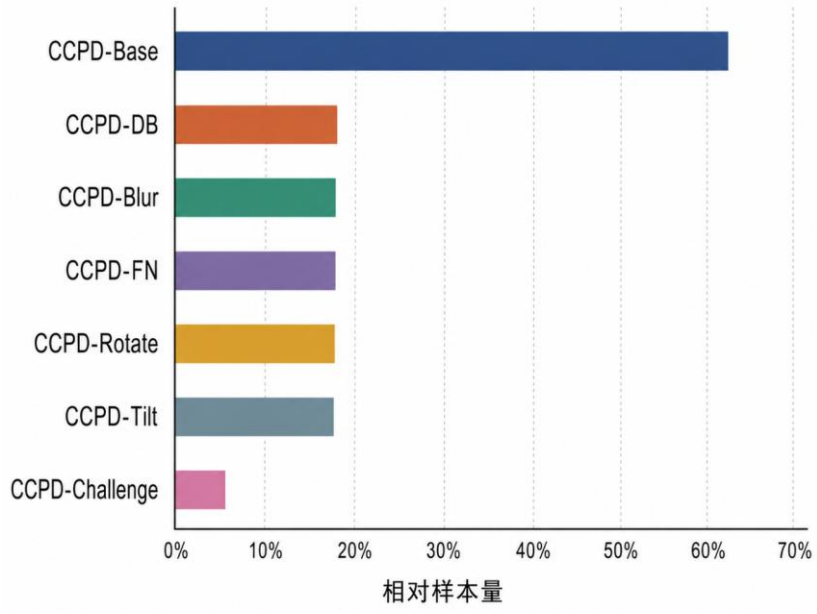


图 4-3　CCPD19 各子场景相对样本分布

在检测任务层面，所有样本均可统一作为“车牌目标”类别参与 YOLO 模型训练，因

此检测阶段不存在明显的类别冲突问题。但在识别任务中，由于蓝牌与绿牌在字符长度上存在差异，需要在标签构建阶段进行区分处理。为保证模型学习稳定性，本文在训练过程中对新能源绿牌样本进行适当增强，包括随机裁剪、亮度扰动及图像旋转等方式，以缓解类别不均衡带来的影响。

在数据集划分方面，本文采用随机分层划分策略，将整体数据按 8:1:1 划分为训练集、验证集和测试集。其中，训练集用于模型参数学习，验证集用于模型训练过程中的超参数调整与过拟合监控，测试集用于最终模型性能评估。划分过程中保证蓝牌与绿牌在各子集中的比例基本一致，从而避免由于类别分布偏差导致评估结果失真。

表 4-2　CCPD2019 与 CCPD2020 对比

数据集	主要车牌类型	字符位数	场景特征	主要用途
CCPD2019	普通蓝牌为主	7 位	普通、模糊、旋转、倾斜、远距离、暗光等	检测和识别主训练数据
CCPD2020	新能源绿牌	8 位	新能源车辆车牌场景	扩展绿牌识别能力

5 边缘 AI 模型开发流程

边缘 AI 模型是本项目实现车牌目标检测、字符识别与端侧视觉感知的核心组成部分。由于系统部署平台为 GD32H759IMK6 微控制器，其片上资源相较于 GPU 服务器和嵌入式 Linux 平台存在明显限制，因此模型开发不能仅关注算法精度，还需要综合考虑模型参数量、计算复杂度、存储占用、INT8 量化稳定性、端侧算子支持情况以及实际推理延迟。本章围绕车牌检测模型与车牌识别模型的开发过程，系统阐述模型从架构选型、训练验证、量化转换到端侧部署的完整流程。

5.1 模型架构选型与设计

本项目的模型选型遵循“精度—效率—可部署性”的综合权衡原则。对于停车巡检场景而言，模型既要能够在复杂环境下准确检测车牌目标，又要满足 GD32H759IMK6 微控制器的资源约束。该芯片 Flash 容量约为 2 MB，SRAM 容量约为 1 MB[6]，除 AI 模型外，系统还需要运行图像采集、数据缓存、云台控制、CAN 通信和任务调度等程序，因此留给 AI 模型的实际存储与运行空间十分有限。基于此，本文从主流轻量级目标检测模型中筛选候选方案，并对其参数量、计算量、检测精度、INT8 量化友好度和 MCU 适用性进行比较，结果如表 5-1 所示。

表 5-1 候选车牌检测模型对比

候选模型	参数量	MACs	mAP@CCPD
YOLO-FastestV2	238 K	0.06 G	0.998
YOLOv5-nano	1.9 M	4.5 G	0.995
YOLOv8-nano	3.2 M	8.7 G	0.997
MobileNet-SSD	6.8 M	1.2 G	0.912
NanoDet-Plus	970 K	0.44 G	0.963
EfficientDet-D0	3.9 M	2.5 G	0.945

由表 5-1 可见，YOLO-FastestV2 在检测精度、模型体积和计算效率之间具有较好的平衡。其参数量仅为 238 K，计算量约为 0.06 G，INT8 模型大小约为 401 KB，实测端侧推理延迟约为 131 ms。相比之下，YOLOv5-nano 和 YOLOv8-nano 虽然在常规嵌入式平台上具有较好的检测性能，但其参数量和计算量明显高于 YOLO-FastestV2，在

GD32H759IMK6 平台上容易导致 Flash 占用过高或 SRAM 峰值溢出。MobileNet-SSD、EfficientDet-D0 等模型参数量更大，端侧部署难度较高。综合考虑后，本文选择 YOLO-FastestV2 作为车牌检测模型[7]。

在车牌识别任务中，模型需要对检测得到的车牌区域进行字符序列识别。候选识别模型包括 CRNN+CTC、MobileNetV2、LPRNet Tiny 和 LPRNet Lite 等[8]，比较结果如表 5-2 所示。

表 5-2 候选车牌识别模型对比

候选模型	参数量	输入尺寸	整牌准确率	推理延迟
CRNN+CTC	8.3 M	100×32	95.2%	>200 ms
MobileNetV2	2.3 M	94×24	92.1%	约 80 ms
LPRNet Tiny	0.105 M	94×24	95.1%	<30 ms
LPRNet Lite	0.35 M	94×24	96.8%	约 50 ms

CRNN+CTC 模型虽然具有较强的序列建模能力，但其循环结构和较大的参数规模不适合 MCU 部署；MobileNetV2 模型用于车牌识别时需要额外设计序列输出结构，且模型体积仍然偏大；LPRNet Lite 识别精度较高，但推理延迟和存储占用高于 LPRNet Tiny。LPRNet Tiny 采用全卷积结构，参数量约为 105 K，输入尺寸为 94×24 灰度图，推理延迟低于 30 ms，较好地满足了端侧实时识别需求。因此，本文选择 LPRNet Tiny 作为车牌字符识别模型[9]。

在系统设计中，YOLO-FastestV2 与 LPRNet Tiny 构成“检测—识别”两阶段视觉流水线。YOLO-FastestV2 首先在 192×192 输入图像上完成车牌区域定位，并输出检测框坐标；随后系统将检测框坐标线性映射至原始图像空间，对车牌区域进行裁剪、缩放、灰度化和量化处理，再输入 LPRNet Tiny 完成字符识别。两个模型在输入预处理方面均采用 8 bit 图像数据，输入 scale 设置为 0.003922，即 1/255，zero point 设置为-128，从而简化 MCU 端预处理流程。需要注意的是，YOLO 和 LPRNet 的输出分布不同，YOLO 输出主要为经过 sigmoid 归一化后的概率值，而 LPRNet 输出为字符分类 logits，因此二者在端侧后处理时应分别使用对应的输出量化参数，不能直接复用同一套反量化逻辑。

5.2模型训练与验证

5.2.1 训练环境与框架

YOLO-FastestV2 检测模型基于 PyTorch 框架训练，并使用 CUDA 进行加速。训练数据采用 CCPD mixed 数据集，该数据集包含标准车牌、模糊车牌、倾斜车牌、旋转车牌、暗光车牌、远距离车牌和恶劣天气车牌等多种场景。训练集约 16 万张图像，验证集约 4 万张图像。模型训练以预训练权重 plate-40-epoch-0.999837ap-model.pth 为基础继续微调，训练批大小为 128，初始学习率为 0.001，优化器采用 Adam。最终模型在验证集上取得 mAP=0.998 的检测效果。

LPRNet Tiny 识别模型同样基于 PyTorch 框架训练。模型输入为 94×24 单通道灰度车牌图像，输出为 7 位车牌字符序列。字符集包括 31 个省份简称和 34 个字母数字类别，共 65 类。模型训练过程中采用字符位置分类损失，对每个字符位置分别进行监督。PC 端验证结果显示，LPRNet Tiny 字符级准确率约为 98%，整牌准确率约为 86%。由于整牌识别要求 7 个字符全部正确，因此整牌准确率低于字符级准确率，符合车牌序列识别任务的基本规律。

5.2.2 训练超参数配置

YOLO-FastestV2 训练超参数如表 5-3 所示。模型输入分辨率设置为 192×192×3，并采用 Letterbox Resize 保持图像宽高比，避免车牌形变对检测效果造成影响。训练过程中使用 Mosaic 增强、HSV 扰动和尺度抖动，以提高模型对复杂停车场景的适应能力。

表 5-3　YOLO-FastestV2 训练超参数配置

超参数	配置值	设计说明
输入分辨率	192×192×3	Letterbox Resize，保持宽高比并进行灰边填充
Batch Size	128	提高批量统计稳定性
训练轮数	280 epoch	包含 40 轮预训练和后续微调
初始学习率	0.001	与 Adam 优化器匹配
学习率衰减策略	Step Decay	170 epoch 和 240 epoch 分别衰减

超参数	配置值	设计说明
优化器	Adam	β1=0.9，β2=0.999
权重衰减	5×10^-4	抑制模型过拟合
Warmup	3 epoch	学习率由 1×10^-6 线性升至 1×10^-3
损失函数	CIoU Loss+BCE	坐标、目标置信度和类别联合优化
Anchor 匹配	IoU>0.3	提高目标召回率
Mosaic 增强	前 70% epoch 启用	提高小目标和多尺度目标检测能力
HSV 扰动	h=±0.015，s=±0.7，v=±0.4	增强光照鲁棒性
尺度抖动	±20%	增强尺度适应性
混合精度	FP16+FP32	降低显存占用，提高训练速度
训练硬件	NVIDIA GPU 32 GB	CUDA 11.8，PyTorch 2.6

LPRNet Tiny 训练超参数如表 5-4 所示。考虑到车牌字符识别任务对局部笔画、边缘和字符排列具有较强依赖，训练阶段加入随机亮度、高斯噪声和随机模糊等增强策略，以提升模型对光照变化、图像噪声和运动模糊的鲁棒性。

表 5-4　LPRNet Tiny 训练超参数配置

超参数	配置值及说明
输入分辨率	94×24×1，灰度图输入
批大小	128
训练轮数	50
初始学习率	0.001
学习率衰减策略	Cosine Annealing，T_max=50，η_min=1×10^-6
优化器	Adam，β1=0.9，β2=0.999

超参数	配置值及说明
权重衰减	1×10^-4
损失函数	Cross-Entropy Loss
数据增强	随机亮度、随机高斯噪声、随机模糊
梯度裁剪	max_norm=5.0
训练硬件	NVIDIA GPU，CUDA 加速

5.2.3 训练过程与收敛分析

YOLO-FastestV2 训练过程主要经历了特征快速学习、精细调优和最终收敛三个阶段。训练前期采用较大的学习率和较强的数据增强，使模型快速学习车牌目标的轮廓、边缘和尺度变化特征；训练中后期逐步降低学习率，使模型在更稳定的参数空间内完成细节优化；训练末期学习率进一步降低，验证集 mAP 逐渐趋于饱和并最终稳定在 0.998 左右。训练集损失和验证集损失整体呈下降趋势，二者之间未出现明显分离，说明模型具有较好的收敛性和泛化能力。

YOLO-FastestV2 训练曲线如图 5-1 所示，包括训练集与验证集损失曲线、验证集 mAP 曲线和学习率调度曲线。

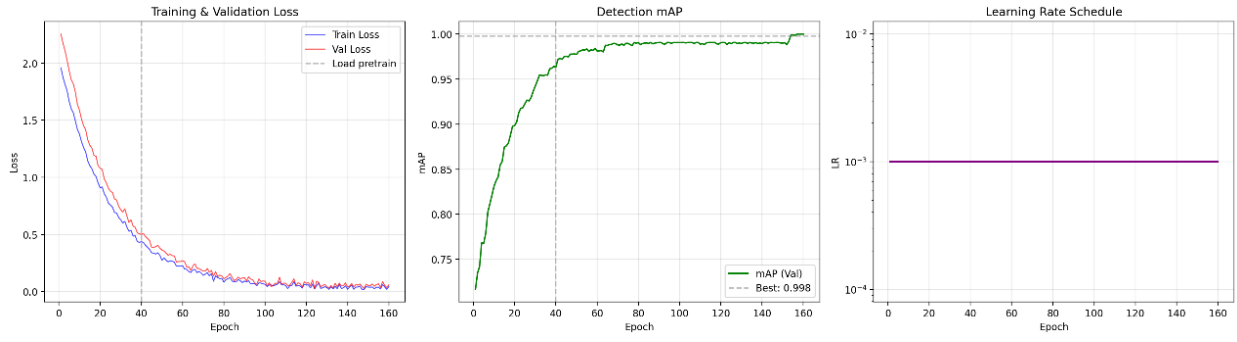


图 5-1 YOLO-FastestV2 训练过程曲线

LPRNet Tiny 训练过程中，模型首先学习车牌字符的低层视觉特征，如边缘、笔画和局部纹理；随后逐渐形成对省份简称、字母和数字的分类能力。由于车牌整牌识别要求 7 位字符全部正确，因此整牌准确率明显低于字符级准确率。

本项目实测整牌准确率约为 0.864，与理论估计值较为接近，说明整牌错误主要来自多个字符位置误差的累积，而不是某一固定字符位置的系统性识别失败。LPRNet Tiny 训练过程如图 5-2 所示，包括训练损失、验证损失、字符级准确率和整牌准确率变化。

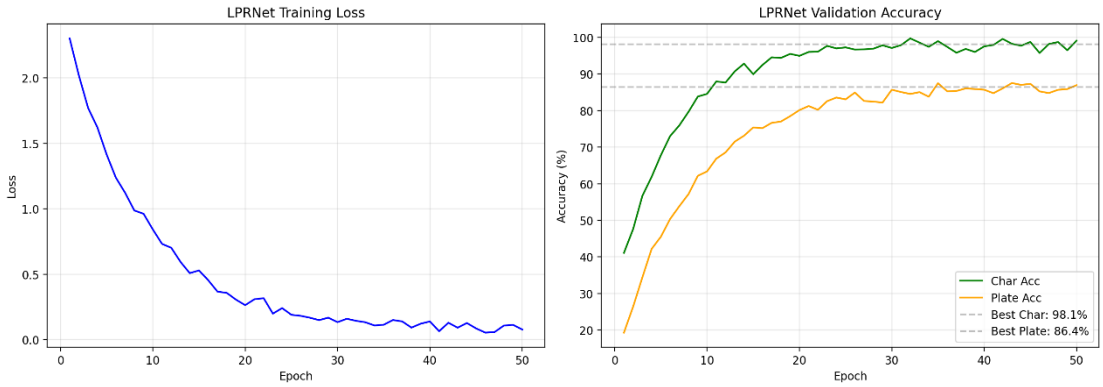


图 5-2　LPRNet Tiny 训练过程曲线

YOLO-FastestV2 采用 ShuffleNetV2 骨干网络[10]与轻量级 FPN 结构[11]，总参数量约 238 K，在 192×192 输入分辨率下输出两个尺度的检测特征图。每个网格单元输出 16 个通道，其中 ch0—ch3 为 anchor0 的回归值，ch4—ch7 为 anchor1 的回归值，ch8—ch11 为 anchor2 的回归值，ch12—ch14 为三个 anchor 对应的 objectness 分数，ch15 为共享分类分数。模型输出经 sigmoid 激活后被映射至[0,1]区间，再通过边界框解码公式还原为图像坐标。

在实际测试中，INT8 模型相较 Float32 参考模型的平均检测框偏差约为 1.9 px，最大偏差为 7.3 px。该偏差虽然大于单层均匀量化的理论误差，但考虑到卷积神经网络中存在多层卷积、非线性激活和特征融合等操作，量化误差会在前向传播过程中逐层累积，因此该结果仍处于合理范围内。实际系统中，后续车牌裁剪阶段通过设置一定比例的边界扩展 margin，可进一步补偿检测框轻微偏移对识别结果造成的影响。

在训练泛化方面，YOLO-FastestV2 训练集损失与验证集损失之间的差值较小，泛化间隙 (\Delta L) 小于 0.02，未出现明显过拟合现象。模型较好的泛化能力主要来源于四个方面：第一，Mosaic 增强、HSV 扰动、随机翻转和尺度抖动等复合数据增强策略增加了训练样本多样性；第二，L2 权重衰减对模型参数范数形成约束，降低了过拟合风险；第三，BatchNorm 层在 mini-batch 统计过程中引入一定随机性，具有隐式正则化作用；第四，采用预训练权重进行微调，使模型在较稳定的初始参数基础上继续优化。消融实验结果显

示，Mosaic 增强对 mAP 提升贡献最大，约提升 0.020；HSV 扰动提高了模型对光照变化的鲁棒性，约提升 0.006；随机翻转增强增加了样本空间变化，约提升 0.007。多种增强策略联合使用后，模型 mAP 相较无增强基线提升约 2.8 个百分点。

5.2.4 模型验证结果

为验证 YOLO-FastestV2 从 Float32 模型转换为 INT8 模型后的输出一致性，本文从 CCPD 8 个类别中随机抽取 20 张图像进行对比测试。测试图像覆盖标准、模糊、倾斜、旋转、暗光、远距离、叠加退化和恶劣天气等场景。所有图像均在 192×192 分辨率下完成推理，并比较 Float32 参考模型与 INT8 部署模型的检测结果。

表 5-6　Float32 与 INT8 检测结果对比

场景类别	Float32 检测	INT8 检测	检测框偏差	置信度范围
ccpd_base	3/3	3/3	0.1–2.7 px	0.977–1.000
ccpd_blur	3/3	3/3	0.3–3.2 px	0.930–0.997
ccpd_challenge	3/3	3/3	0.4–7.3 px	0.559–0.984
ccpd_db	3/3	3/3	0.2–1.8 px	0.984–1.000
ccpd_fn	2/2	2/2	0.5–3.0 px	0.777–0.992
ccpd_rotate	2/2	2/2	1.0–2.2 px	0.797–0.988
ccpd_tilt	2/2	2/2	0.2–2.7 px	0.988–0.992
ccpd_weather	2/2	2/2	0.5–0.7 px	0.992–0.994

测试结果显示，Float32 模型和 INT8 模型在 20 张测试图像中均完成了车牌检出，检测结果均为 20/20。INT8 模型相较 Float32 模型的平均检测框偏差约为 1.9 px，占 192×192 输入分辨率的 1.0%；最大检测框偏差为 7.3 px，占输入分辨率的 3.8%。该结果表明，模型量化与转换并未导致明显检测失败，INT8 部署模型与 Float32 参考模型具有较好一致性。需要说明的是，该测试主要用于验证模型转换与量化前后的输出一致性，不能完全替代大规模测试集上的泛化性能评估。

LPRNet Tiny INT8 模型在 CCPD base 类别 1000 张随机采样测试集上的识别结果如表 5-7 所示。

表 5-7　LPRNet Tiny 识别模型验证结果

指标	结果
整牌准确率	86.4%
字符级准确率	98.1%
省份位置准确率	95.2%
字母数字位置准确率	97.3%

由表 5-7 可见，LPRNet Tiny 具有较高的字符级识别准确率，但整牌准确率低于字符级准确率。这是由于整牌识别需要 7 个字符全部正确，任何一个字符识别错误都会导致整牌识别失败。对于实际应用场景，系统可通过连续多帧识别结果滤波、置信度加权投票和车牌编码规则约束等方式进一步提高整牌输出稳定性。

从跨场景表现来看，在 challenge 类别中，YOLO-FastestV2 的检测框偏差相对较大，最大偏差达到 7.3 px。这说明在多因素复合退化场景下，模型定位精度会有所下降。但由于后续车牌裁剪阶段设置了约 15%的边界扩展 margin，该偏差仍可被识别模型的输入冗余范围吸收，不会直接导致车牌字符区域缺失。由此可见，YOLO-FastestV2 与 LPRNet Tiny 构成的级联识别流程具有一定容错能力。

综上，本文所构建的边缘 AI 模型开发流程在 GD32H759IMK6 资源约束下实现了车牌检测与字符识别功能。YOLO-FastestV2 在模型大小、推理延迟和检测稳定性方面满足端侧部署要求；LPRNet Tiny 在较低参数量和较短推理时间下实现了较高字符级准确率。通过模型轻量化选型、INT8 量化、通道操作优化、独立量化参数解析、检测框 margin 裁剪和多帧识别滤波等方法，系统在精度、实时性和端侧可部署性之间取得了较好的平衡，为后续车牌目标跟踪、自主巡检和停车管理决策提供了可靠的视觉感知基础。

5.2.5 模型优化与压缩

为满足 GD32H759IMK6 平台对模型存储空间、运行内存和推理效率的约束，本项目在模型训练完成后对 YOLO-FastestV2 检测模型和 LPRNet Tiny 识别模型进行了优化与压缩。优化工作的目标并非单纯追求模型体积最小化，而是在保证检测定位和字符识别能力

基本稳定的前提下，降低模型文件大小、简化端侧推理计算，并提高模型转换与部署过程的可靠性。

结合两个模型本身已经较为轻量的特点，本文最终采用以 INT8 训练后静态量化为核心、以轻量化网络结构和模型转换适配为支撑的优化路线；对于剪枝和知识蒸馏等常见压缩技术，则结合模型规模、精度损失和工程复杂度进行了取舍分析。

（1）优化策略总览如表 5-8 所示：

表 5-8 模型优化与压缩技术设计

优化技术	具体方法	实施细节
量化	INT8 训练后静态量化（PTQ）	采用 TensorFlow Lite 原生 TFLiteConverter 完成模型转换与量化；校准数据由 CCPD 多类别样本随机抽取 500 张构成；权重和激活值采用 INT8 表示，偏置采用 INT32 累加；量化区间通过 MinMax 校准确定。
剪枝	未采用	YOLO-FastestV2 和 LPRNet Tiny 参数量已较小，继续剪枝带来的体积收益有限；实验中较高稀疏度会引起检测精度下降，因此保留完整网络结构以保证特征表达稳定性。
蒸馏	未采用	两个轻量模型直接训练后已达到设计精度要求；教师—学生蒸馏会增加教师模型构建、温度系数和损失权重调节等额外成本，边际收益有限。
轻量化设计	轻量骨干与全卷积识别结构	检测模型采用 ShuffleNetV2 骨干和深度可分离卷积，降低参数量与乘加运算量；识别模型采用 LPRNet Tiny 全卷积结构，避免 RNN/LSTM 循环计算，提高端侧适配性。
转换适配	Keras 重建与权重迁移	采用“PyTorch 训练—Keras 重建—TFLite 导出”的转换路线；对 BatchNormalization 参数进行一致性处理，并完成卷积、深度卷积和 BN 权重的维度转换与迁移，以规避 ONNX 到 TFLite 转换兼容问题。

由表 5-8 可见，本项目的模型优化重点在于量化和结构轻量化。INT8 量化主要用于降低模型存储占用和整数推理计算量[11]；轻量化结构设计则从网络架构层面减少参数规模和运算复杂度；转换适配用于保证模型由训练框架迁移至部署框架后的结构一致性和参数正确性。相比之下，剪枝和蒸馏虽然是常见模型压缩方法，但在本项目的小规模模型场景中收益较低，因此未作为最终部署方案。

（2）优化前后参数对比

为评价模型优化与压缩效果，本文主要从模型大小、参数量、数值精度形式和总体存储占用等方面对优化前后的模型进行对比。端侧实测精度、推理延迟和运行资源占用将在后续系统测试章节中单独分析，本节不再展开。

表 5-9 模型优化前后关键指标对比

指标	优化前	优化后	优化效果
YOLO 模型大小	987 KB（Float32 ONNX）	316 KB（INT8 TFLite）	压缩约 2.46 倍，节省约 586 KB
YOLO 参数量	238,496	238,496	结构保持不变，参数数量不变
YOLO 数值精度	Float32	INT8	降低数值位宽，适配整数推理
LPRNet 模型大小	415 KB（Float32 TFLite）	156 KB（INT8 TFLite）	压缩约 3.52 倍，节省约 297 KB
LPRNet 参数量	105,216	105,216	结构保持不变，参数数量不变
LPRNet 数值精度	Float32	INT8	降低数值位宽，减少存储开销
两模型文件合计	约 1,402 KB	约 472 KB	压缩约 2.70 倍，占 2 MB Flash 约 26%
模型部署形式	训练与验证阶段浮点模型	面向端侧部署的 INT8 模型	满足后续嵌入式部署需求

从表 5-9 可以看出，量化后两个模型的参数数量保持不变，模型压缩主要来自数值表示精度由 Float32 降低为 INT8。YOLO-FastestV2 模型文件由 987 KB 降低至 401 KB，LPRNet Tiny 模型文件由 415 KB 降低至 118 KB，两模型合计大小由约 1,402 KB 降低至约 472 KB，整体压缩约 2.70 倍。该结果表明，INT8 训练后静态量化能够在不改变网络结构的情况下显著降低模型存储占用，为系统程序代码、外设驱动、图像缓存和通信模块预留了必要空间。

（3）优化流程说明

本项目模型优化流程可概括为“轻量化模型训练—模型结构重建—权重迁移—INT8 量化—部署模型导出”。首先，在模型选型阶段优先选择参数量较小、算子结构较简单的

轻量网络，减少后续压缩压力；其次，在模型转换阶段采用 Keras 重建方式对 YOLO-FastestV2 网络结构进行复现，并通过名称映射和维度转换完成 PyTorch 权重迁移；最后，使用 TensorFlow Lite 原生工具完成 INT8 训练后静态量化，生成适用于后续端侧部署的 TFLite 模型文件。

该优化路线避免了复杂 ONNX 图转换过程中可能出现的维度映射和算子兼容问题，同时保持了模型结构的完整性。通过上述方法，本文在保证模型可部署性的基础上显著降低了模型体积，为后续端侧推理测试和整机系统联调奠定了基础。

5.3边缘部署

本项目采用“先检测、后识别”的两阶段车牌识别方案。第一阶段由 YOLO-FastestV2 完成车牌区域检测，输出车牌边界框；第二阶段根据检测框裁剪车牌区域，并输入 LPRNet Tiny 完成车牌字符识别。该方案结构清晰，便于分别优化检测和识别模型，也更适合在 MCU 资源受限条件下进行端侧部署。模型开发流程如图 5-3 所示。

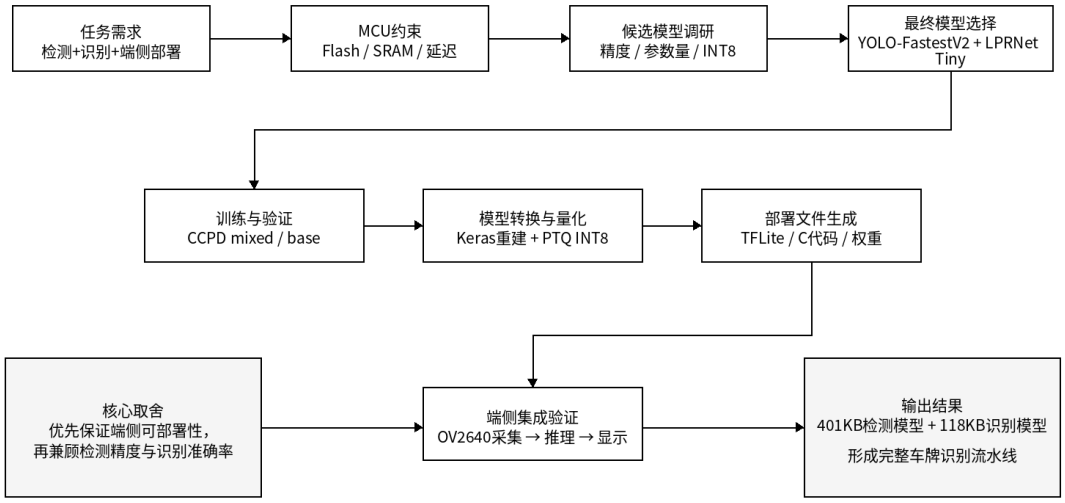


图 5-3　边缘 AI 模型开发流程

5.3.1 边缘 AI 部署步骤

本系统采用 GD32H759I Cortex-M7 作为主控芯片，在裸机环境下完成车牌检测、车

牌字符识别和云台跟踪等功能。AI 模型部署采用 GD32 Embedded AI Tool 完成模型转换与导入 keil 工程。

（1）输入模型格式（.tflite / .onnx / 其他）

本系统包含两个端侧 AI 模型，均为.tflile 格式。分别为车牌检测模型和车牌字符识别模型。

（2）工具链版本及配置参数如表 5-10 所示。

表 5-10　边缘部署环境

工程环境	参数
GD32 Embedded AI Tool	1.2.0.39432
Keil MDK	5.34.0.0
C Compiler	6.16
GD32H7xx Firmware Library	1.4.0

（3）模型转换过程（含截图）

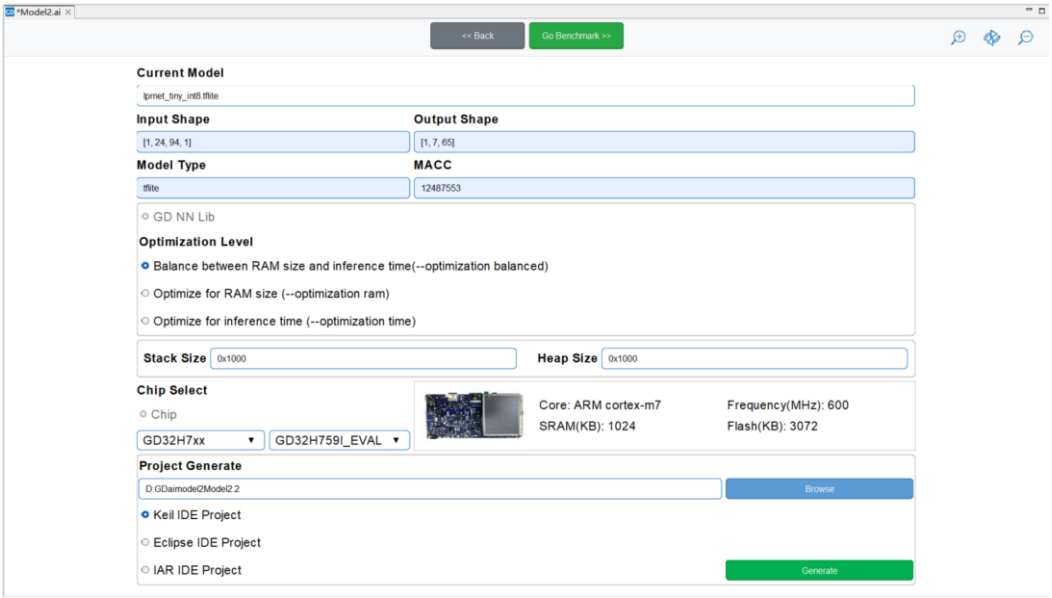


图 5-4　模型转换过程

转换后模型的核心文件包括模型配置文件、推理运行库、链接脚本及端侧后处理代码。其中，nn_model_configure.c 为主要模型 C 代码文件，包含 YOLO 检测模型和 LPRNet 识别模型的参数数组、算子回调表、模型名称及静态内存池等信息；nn_model_configure.h 定

义模型输入输出大小、输出节点数量、静态缓冲区大小和相关宏参数，例如 YOLO 输入大小为 110592，LPRNet 输入大小为 2256，公共静态缓冲区峰值为 334400 字节。GD_LIB_CM7_v212.lib 为 GD32 AI 推理运行库，提供 nn_model_init()、nn_model_invoke()及各类神经网络算子实现。GD32H759.sct 用于配置模型权重和缓存区在 Flash、AXI SRAM及外部 RAM 中的存放位置。端侧配套代码包括 trans.c、yolo_plate_postprocess.c 和 license plate display.c，分别完成输入格式转换、YOLO 检测框解码与 NMS、车牌裁剪、识别输入生成和字符解码显示。

模型集成采用“静态数组编译进固件”的方式，模型结构、权重和量化参数在编译阶段写入工程，系统启动后调用 nn_model_init() 完成模型初始化。内存分配以静态分配为主，YOLO 和 LPRNet 共用 static_buffer_peak 作为输入、输出和中间 tensor 缓冲区，通过串行推理方式分时复用内存。实际链接中，主要权重数据分别放置于 Flash、AXI SRAM 和 AXI_EXT_RAM 等区域，以减轻片上存储压力。

推理流程由 app_vision_process_camera_frame() 统一调度。摄像头帧准备完成后，系统首先通过 trans.c 将 RGB565 图像转换为 192×192×3 的 NHWC int8 输入，并调用 nn_model_invoke(plate_model) 执行 YOLO 车牌检测。检测输出包含两个 int8 检测头，经反量化、anchor 解码、置信度筛选、宽高比过滤和 NMS 后得到车牌框。随后系统根据检测框对原图进行扩边裁剪，将车牌区域转为灰度并缩放至 94×24，再按 gray-128 转换为 LPRNet 输入，调用 nn_model_invoke(lprnet_model) 完成字符识别。

LPRNet 输出大小为 455，即 7×65 个字符分类结果。后处理阶段对每个位置进行 argmax 解码，其中首位限定为省份字符，后 6 位限定为字母和数字类别，最后映射为 UTF-8 车牌字符和 ASCII 调试字符串。为降低单帧识别波动，工程在 app_vision.c 中加入三帧投票滤波机制，并将最终车牌结果输出至 LCD 屏幕和串口端。

5.3.2 端侧推理性能评估

表 5-11 和表 5-12 分别给出了 Model 1 和 Model 2 在 GD32H759 平台上的端侧推理性能评估结果。从整体性能来看，两个模型均能够满足嵌入式端侧部署需求，但在识别精度、推理速度和资源占用方面具有不同的特点。

其中，Model 1 作为目标检测模型，在 500 张测试样本上的端侧实测精度达到 94%，单次平均推理时间为 101 ms，对应推理速度约为 10 fps。模型编译后占用 Flash 空间 309 KB，运行过程中的峰值 RAM 占用为 349 KB。虽然检测模型计算复杂度相对较高，运行

时内存占用较大，但其仍能够在 GD32H759 有限的片上资源条件下完成实时目标检测任务，为后续车牌裁剪和字符识别提供准确的目标定位信息。

表 5-11　Model 1 端侧推理性能评估

端侧性能指标	实际值	测试条件说明
模型精度	94%	端侧实测，测试集样本数：500
单次推理延迟	101 ms	运行 100 次取平均
推理帧率（FPS）	10 fps	（如适用）
模型占用 Flash 空间	309 KB	编译后实际占用
模型推理时 RAM 占用	349 KB	运行时实际峰值占用

表 5-12　Model 2 端侧推理性能评估

端侧性能指标	实际值	测试条件说明
模型精度	92%	端侧实测，测试集样本数：500
单次推理延迟	20 ms	运行 3 次取平均
推理帧率（FPS）	50 fps	（如适用）
模型占用 Flash 空间	152 KB	编译后实际占用
模型推理时 RAM 占用	81 KB	运行时实际峰值占用

相比之下，Model 2 作为车牌字符识别模型，端侧实测精度达到 92%，单次平均推理时间仅为 20 ms，推理速度可达到 50 fps，明显快于 Model 1。与此同时，其 Flash 占用仅为 152 KB，峰值 RAM 占用为 81 KB，资源消耗显著低于检测模型。这主要是由于 LPRNet Tiny 采用轻量级全卷积网络结构，模型参数规模较小，计算量较低，因此能够在保证较高识别准确率的同时实现快速推理。

综合两个模型的测试结果可以看出，目标检测模型承担了较大的计算负载，而字符识别模型具有更高的推理效率和更低的资源消耗。两者在系统中形成“检测—识别”级联处理流程后，整体模型 Flash 占用约 461 KB，运行峰值 RAM 约 430 KB，总体资源占用均低于 GD32H759 芯片的硬件资源限制，能够满足停车巡检系统对实时性、准确性和轻量化部署的要求，为后续目标跟踪和车牌信息采集提供了可靠的端侧计算能力。

6 系统软硬件设计方案

本章主要介绍系统软硬件设计方案。硬件方面，系统以 GD32H759I 主控单元为核心，围绕端侧视觉识别、云台电机控制、传感器采样和多接口通信等功能，完成了摄像头接口、电机驱动、电源管理、通信接口和传感器采样等电路设计；软件方面，系统采用裸机前后台式架构，通过主循环轮询、DMA 数据搬运、CAN 通信和外设中断机制，实现图像采集、AI 推理、车牌识别、结果输出和云台跟踪控制。通过软硬件协同设计，系统形成了“图像感知—车牌识别—目标跟踪—状态反馈”的闭环工作流程，为后续系统联调、性能测试和停车智能管理功能实现提供了基础。

6.1 系统硬件总体方案

本系统硬件围绕“端侧视觉识别、云台电机控制、传感器状态反馈与多接口通信”四类核心功能进行设计。根据压缩包中的原理图文件，硬件部分主要由 GD32H759I 主控单元、摄像头图像采集接口、边缘 AI 推理相关存储与外设接口、两路三相无刷电机驱动电路、姿态与测距传感器接口、CAN/RS485/串口等通信接口以及多级电源管理电路组成。系统总体方案如图 6-1 所示。

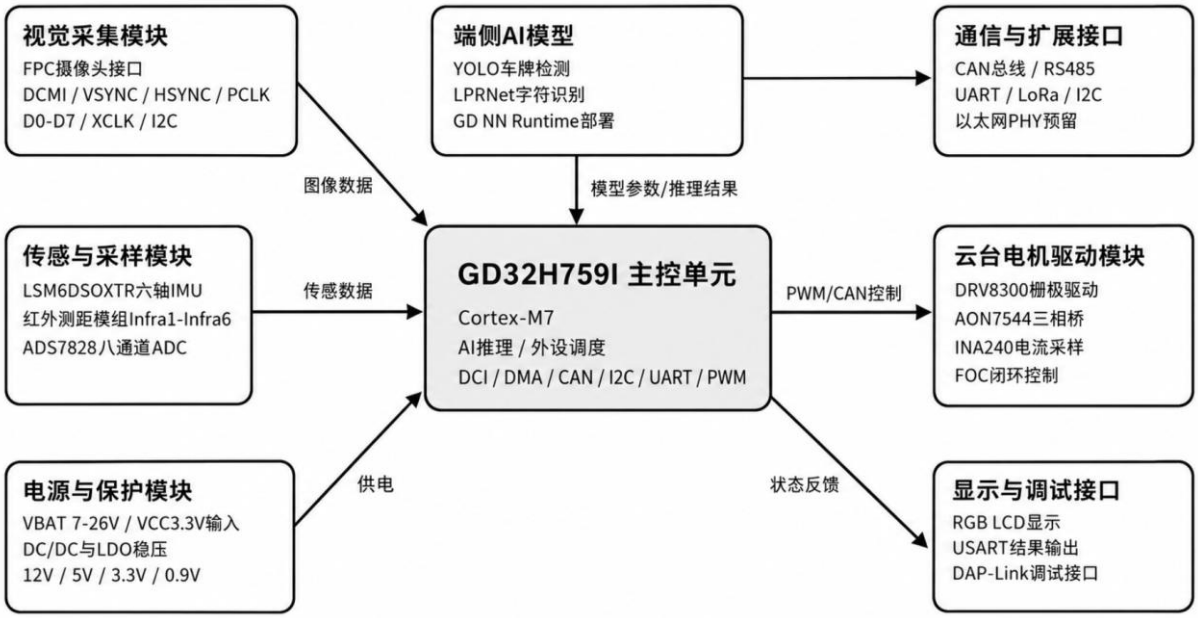


图 6-1　系统硬件总体方案图

6.1.1 硬件功能模块划分

从功能实现角度看，系统采用“主控计算 + 视觉采集 + 电机驱动 + 传感反馈 + 电源管理”的模块化结构。主控单元负责图像采集控制、AI 模型推理调度、CAN 命令解析和云台控制逻辑；摄像头接口提供并行图像数据输入；电机驱动模块完成两轴云台电机的三相桥驱动与电流反馈；IMU、红外测距和 ADC 采样电路用于提供姿态、距离和电气状态信息；电源模块则为主控、传感器、通信接口和功率驱动部分提供稳定供电。

表 6-1　系统硬件模块及主要功能

模块名称	主要器件/接口	关键信号	功能说明
主控计算模块	GD32H759I Cortex-M7	DCMI、DMA、CAN、I2C、UART、PWM	完成图像采集调度、AI 推理、通信解析和控制策略执行
视觉采集模块	FPC-05-18P 摄像头接口	DCMI_D0-D7、PCLK、VSYNC、HSYNC、XCLK、SCL/SDA	采集 RGB565 图像并送入端侧视觉处理流程
电机驱动模块	DRV8300DRGER-JSM、AON7544、INA240A1PWR	三相 U/V/W、HIN/LIN、相电流采样	实现云台电机三相桥驱动、FOC 控制和电流闭环反馈
传感与采样模块	LSM6DSOXTR、ADS7828EIPWRQ1、红外测距接口	SCL/SDA、6D_INT1/2、Infra1-Infra6	提供姿态、距离和多通道模拟量采样信息
通信接口模块	SIT1042AQT/3、SIT3088EESA、LAN8720A	CAN_H/L、RS485_A/B、UART/LoRa、RMII	实现外部控制命令、状态上报和扩展通信
电源管理模块	TPS5430、TPS54560、TPRT9013-33、RT9048	VBAT、VCC35V、12V、5V、3.3V、0.9V	完成输入保护、多级降压、LDO 稳压和系统供电分配

6.1.2 供电与资源配置方案

系统供电采用多级电源架构。云台主控与电机驱动部分以 VBAT 7-26 V 作为主要输入，底盘及扩展接口部分还包含 VCC35V 输入链路。原理图中通过 TPS5430、TPS54560 等 DC/DC 芯片完成高压到中低压的降压转换，并通过 TPRT9013-33、RT9048 等稳压器生成 3.3 V 和 0.9 V 等低压电源。不同电源网络分别供应电机驱动、主控内核、外设 IO、

传感器和通信接口，能够降低功率级开关噪声对主控和模拟采样电路的影响。

在存储和接口资源方面，主控单元需要同时承担图像数据搬运、模型推理、LCD 显示、串口输出和 CAN 控制等任务。因此，硬件上采用 DCI/DCMI 与 DMA 配合完成图像输入，使用静态缓冲区和外部存储区域保存图像帧与中间数据，并通过 CAN、USART、I2C 和 PWM 等片上外设分别连接云台电机、识别结果输出、传感器和调试接口。

6.2 系统原理图设计

系统原理图按功能划分为电源管理、主控最小系统、电机驱动与电流采样、摄像头接口、传感器采样以及通信接口等部分。图 6-2 给出了各功能电路之间的信号关系。

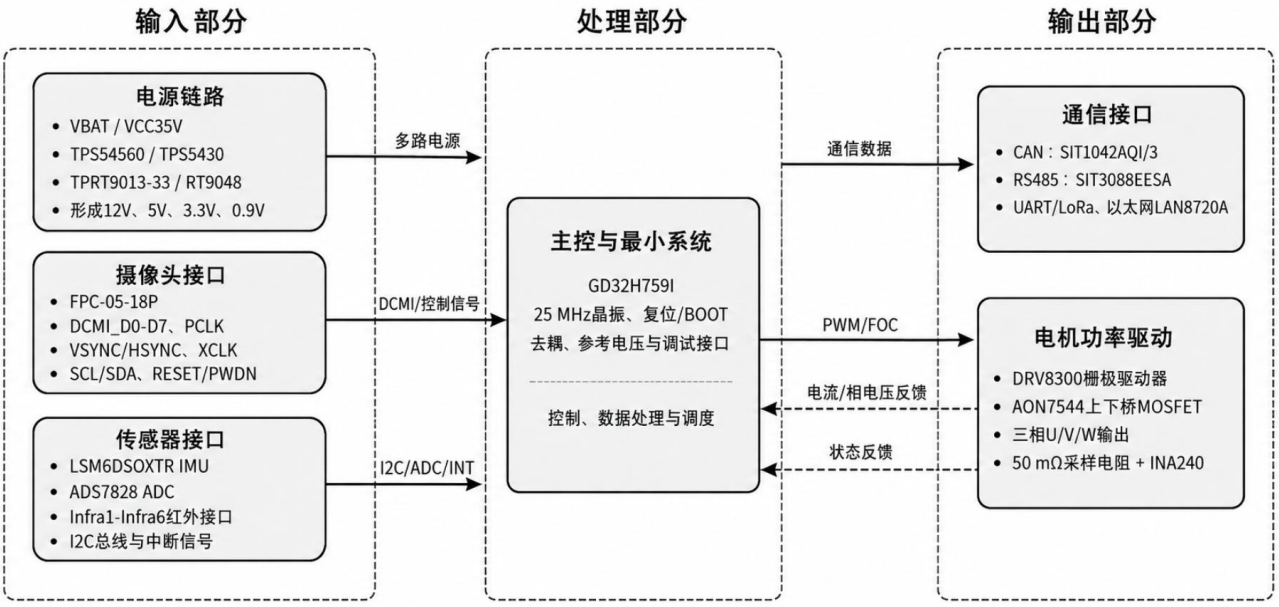


图 6-2　硬件原理功能示意图

系统原理图中的主要功能电路主要包括电源管理、主控最小系统、电机驱动、摄像头接口、传感器采样和通信接口等部分，如表 6-2 所示。从表中可以看出，本系统硬件设计以 GD32H759I 主控为核心，通过电源管理电路为各功能模块提供稳定供电，通过摄像头接口和传感器采样电路完成图像与环境信息采集，并通过电机驱动电路实现云台电机控制。

表 6-2 原理图主要功能电路设计要点

功能电路	关键器件	设计重点	作用
电源管理	TPS5430、TPS54560、TPRT9013-33、RT9048	输入保护、分级降压、去耦滤波	为功率级、主控、传感器和通信模块提供稳定电源
主控最小系统	GD32H759I、25 MHz 晶振、NRST/BOOT、DAP-Link	时钟、复位、调试和电源完整性	保证主控稳定启动并支持程序下载调试
电机驱动	DRV8300、AON7544、50 mΩ 采样电阻、INA240	三相桥驱动、相电流检测、过流反馈	实现云台电机 FOC 闭环控制
摄像头接口	FPC-05-18P	并行数据、同步信号、XCLK 与 I2C 配置	完成图像采集与摄像头控制
传感器采样	LSM6DSOXTR、ADS7828、LM358	I2C 通信、中断输入、模拟信号调理	提供姿态、距离和电气状态信息
通信接口	SIT1042AQT/3、SIT3088EESA、LAN8720A	总线收发、阻抗匹配、接口保护	实现外部控制、状态上报和网络扩展

6.2.1 电源输入与稳压电路设计

电源电路是系统稳定运行的基础。根据原理图，系统包含 VBAT 和 VCC35V 等输入电源网络，并在输入端配置大容量电容、瞬态抑制器件、肖特基二极管和开关控制器件，用于抑制浪涌、电压尖峰和反向冲击。降压部分采用 TPS5430、TPS54560 等开关电源芯片，将高压输入转换为 VCC12V、5V 等中间电源，再通过低压差线性稳压器生成+3.3 V、MCU_3V3 和 MCU_0V9 等低压电源，为主控核心、外设 IO、传感器和通信芯片供电，详细电路图见附录。

该电源架构将功率驱动电源、逻辑电源和传感器电源进行相对独立的分配，有利于降低电机功率级开关电流对主控和模拟采样电路的干扰。同时，在各电源引脚附近布置 100 nF 去耦电容以及 10 uF 级储能电容，可提高电源瞬态响应能力，保证高速数字电路和模拟采样电路的供电稳定性。

6.2.2 主控最小系统与通信接口设计

主控最小系统以 GD32H759 为核心，主要用于完成系统启动、外设初始化、图像采集控制、AI 模型推理调度、识别结果处理和云台控制等任务。电路设计包括主控供电、时钟、复位、启动配置和调试接口等部分。主控工作电源由系统稳压模块提供，并在各电源引脚附近布置去耦电容，以降低图像采集、LCD 刷新和电机控制过程中产生的电源噪声影响。时钟部分采用外部晶振配合芯片内部 PLL 产生系统运行所需时钟，为 CPU 内核、摄像头接口、DMA、LCD、UART 和 CAN 等外设提供稳定时序。复位电路设置独立复位按键和上拉电阻，启动模式默认配置为片上 Flash 启动，以保证系统上电后能够自动进入主程序运行。同时，预留 DAP/SWD 调试接口，便于程序下载、在线调试和故障定位。

通信接口方面，系统根据不同功能模块的数据交互需求设置 UART、CAN 和 RS485 接口。UART 主要用于 GD32H759 与 ESP32 通信模块或上位调试终端之间的数据传输，可输出车牌识别结果、检测置信度、目标坐标和系统运行状态。CAN 接口主要用于与二轴云台电机控制板、底盘控制模块等执行单元进行实时通信，主控根据车牌检测框位置计算目标偏差后，通过 CAN 发送偏航轴和俯仰轴控制指令，实现云台目标跟踪。RS485 接口作为扩展通信接口，可用于后续接入外部传感器或工业通信设备。为提高系统可靠性，各通信接口在硬件设计中需注意电平匹配、ESD 保护、终端匹配和抗干扰布线，避免电机驱动、电源纹波等因素影响通信稳定性。

6.2.3 电机驱动与电流采样电路设计

云台电机驱动部分采用三相无刷电机驱动方案。原理图中每个电机驱动通道均由 DRV8300DRGER-JSM 栅极驱动器、AON7544 功率 MOSFET、三相 U/V/W 输出网络以及相电流采样电路组成。主控通过 HIN/LIN 等控制信号驱动 DRV8300，DRV8300 进一步控制上下桥 MOSFET 导通，实现三相桥逆变输出，详细电路图见附录。

在电流反馈方面，系统在相线回路中配置 50 mΩ采样电阻，并采用 INA240A1PWR 电流检测放大器对采样电压进行放大。INA240 具有较强的共模抑制能力，适合用于 PWM 开关环境下的电机相电流检测[13]。电流采样结果送入主控 ADC 通道后，可用于 FOC 电流闭环、过流保护以及电机运行状态判断。该设计为云台电机实现高响应、高稳定性的闭环控制提供了硬件基础。

6.2.4 摄像头图像采集接口设计

视觉采集电路采用 FPC-05-18P 摄像头接口，与主控的 DCI/DCMI 并行图像采集外设连接。接口信号包括 DCMI_D0-D7 八位数据线、DCMI_PCLK 像素时钟、DCMI_VSYNC 场同步、DCMI_HSYNC 行同步、DCMI_XCLK 摄像头主时钟，以及 DCMI_SCL、DCMI_SDA 配置总线。此外，接口还包含 RESET 和 PWDN 等控制信号，用于摄像头复位和低功耗控制，详细电路图见附录。

该接口能够支持 RGB565 等并行图像格式采集，并可配合 DMA 将图像数据直接搬运至帧缓冲区，减少 CPU 参与图像搬运的时间开销。图像采集完成后，主控调用端侧预处理和 AI 推理流程，完成车牌检测和字符识别。

6.3 系统软件总体方案

本系统软件运行于 GD32H759I Cortex-M7 微控制器平台，采用裸机前后台式软件架构。系统以主循环轮询作为任务调度核心，以 SysTick 提供毫秒级时间基准，以 DCI、DMA、EXMC、LCD、USART 和 CAN 等片上外设完成图像采集、显示、通信和运动控制。AI 推理部分基于 GD NN Runtime，将车牌检测模型和字符识别模型部署到端侧，实现图像采集、车牌定位、字符识别、结果显示和云台跟踪的闭环处理。

软件启动后首先完成系统基础服务初始化，如图 6-4 所示，包括中断向量表、MPU、Cache、SysTick 和延时服务配置；随后初始化外部 SDRAM、RGB LCD、摄像头接口、识别结果串口、CAN 云台控制接口；最后完成两个神经网络模型的参数绑定和运行时初始化。系统进入主循环后，持续轮询摄像头帧状态和云台发送状态，当 DCI＋DMA 完成一帧图像采集后，调用视觉处理流程完成单帧推理和结果输出。

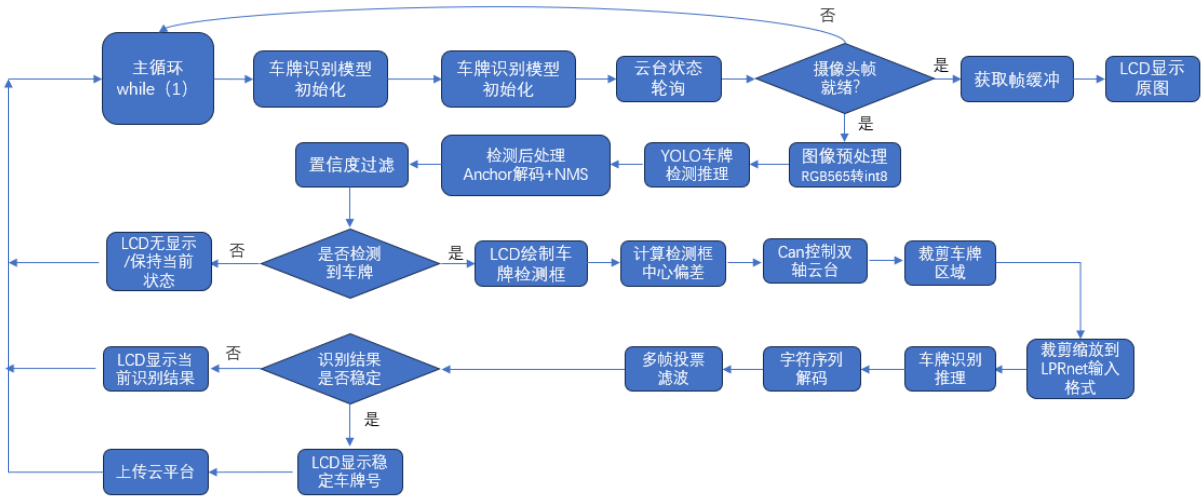


图 6-3　系统主循环结构图



图 6-4　系统初始化顺序图

（1）整体处理链路：摄像头采集 RGB565 图像，经端侧预处理转换为模型输入；YOLO 车牌检测模型输出候选框；后处理模块完成 Anchor 解码、阈值过滤和 NMS；随后裁剪车牌区域并生成 LPRNet 输入；字符识别模型输出 7 位字符分类结果；系统对识别结果进行格式校验、投票滤波，并通过 LCD、UART 和 CAN 输出。

（2）运行调度方式：系统没有引入 RTOS，采用 while(1) 主循环串行调度。耗时较高的图像搬运工作由 DMA 承担，摄像头采集状态通过轮询检查，AI 推理在帧就绪后同步执行，云台控制命令在主循环中分步发送。

（3）内存组织方式：模型输入、输出和中间数据主要使用静态缓冲区管理。检测模型和识别模型共用 static_buffer_peak 等静态内存池，减少动态分配带来的不确定性；摄像头帧缓冲区位于 SDRAM 中，并划分为 DMA 可访问区域，以保证图像采集稳定性。

（4）可靠性设计：摄像头模块记录 DMA 余量、DCI 状态、溢出次数、停滞次数等

调试信息。当长时间无新帧、DMA 错误或 DCI 溢出时，系统会执行 dci_restart() 或摄像头硬恢复流程，提高连续运行稳定性。

如图 6-5 所示，电机控制软件整体采用“初始化—高速闭环控制—通信与安全保护”的运行流程。系统上电后首先进入 main() 函数，完成 RCU、GPIO、ADC、PWM、编码器、系统定时器和中断等基础外设初始化，并进一步完成 MCT、FOC、PWM、Encoder 和 Control 等控制模块配置。初始化完成后，系统进行上电自检，对母线电压、相电流偏置等关键参数进行检测和标定，自检通过后进入 IDLE 状态，等待控制命令。

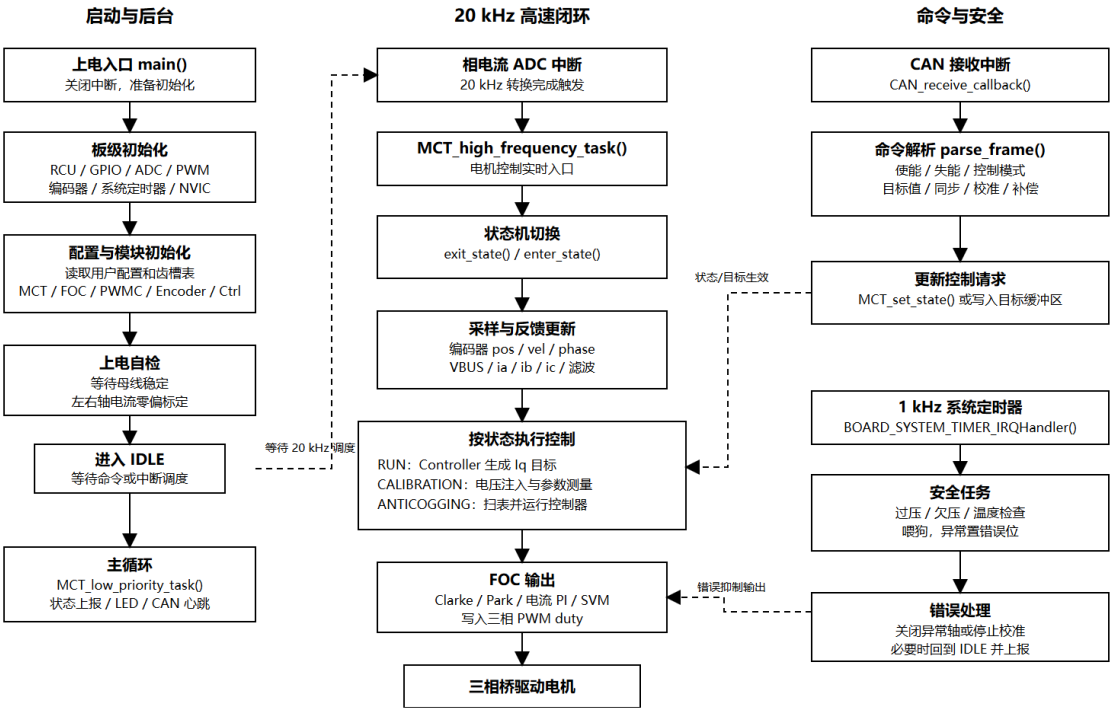


图 6-5　电机程序结构图

系统核心控制过程由 20 kHz 相电流 ADC 中断触发。在每次中断中，程序进入 MCT_high_frequency_task()，完成状态机切换、编码器位置与速度、电压母线及三相电流等反馈量更新，并根据当前状态执行 RUN、CALIBRATION 或 ANTICOGGING 等控制任务。随后系统进行 FOC 运算，包括 Clarke 变换、Park 变换、电流 PI 调节和 SVPWM 生成[14]，最终将 PWM 占空比写入三相桥驱动电路，实现电机闭环控制。

右侧流程主要用于命令交互和安全保护。CAN 接收中断负责接收外部控制命令，并通过 parse_frame() 解析使能、失能、控制模式、目标值、校准和补偿等指令，再通过 MCT_set_state() 更新控制状态。同时，1 kHz 系统定时器周期性执行安全检测任务，对过

压、欠压、温度异常和运行错误等情况进行监测。一旦发生异常，系统进入错误处理流程，关闭异常输出，必要时回到 IDLE 状态并上报故障信息。

综上所述，本系统软件整体采用“端侧视觉感知—车牌识别处理—云台运动控制—状态反馈保护”的闭环设计思路。在 GD32H759I 微控制器平台上，系统通过裸机前后台架构完成图像采集、AI 推理、结果输出和云台控制等任务，并利用 DMA、静态内存池和外设中断机制降低 CPU 负担，提高运行稳定性。视觉识别部分以主循环轮询和帧就绪触发为核心，实现了从摄像头采集到车牌检测、字符识别和结果输出的完整处理链路；电机控制部分则依托 20 kHz 高速闭环任务、CAN 命令解析和 1 kHz 安全检测机制，实现了云台电机的实时控制与故障保护，为后续实现移动巡检、目标跟踪和停车智能管理提供了稳定的软件基础。

6.4 系统模块设计

6.4.1 数据采集模块

数据采集模块负责摄像头初始化、图像帧接收、帧缓冲管理和异常恢复。系统通过 SCCB/I2C 对 OV2640 摄像头进行寄存器配置，设置输出格式为 RGB565，输出尺寸为 192×192。摄像头并口数据由 DCI 接口接收，并通过 DMA 搬运到 SDRAM 中的双缓冲区，CPU 只需轮询帧完成标志即可获取完整图像。

（1）采集接口：摄像头数据经 DCI 接口输入，DMA 使用外设到存储器模式写入 camera_buff 双缓冲区，降低 CPU 参与度。

（2）帧状态管理：dci_check_ready() 根据 DMA 完成标志、DCI 溢出标志和 DMA 错误标志判断当前采集状态。当返回完整帧状态后，上层通过 dci_frame_buffer_get() 获取就绪帧地址。

（3）异常恢复：当出现 DCI 溢出、DMA 错误、半帧停滞或长时间无帧时，模块会触发捕获重启或摄像头硬恢复，重新配置 DCI、DMA 和摄像头寄存器。

（4）输出数据：模块输出一帧 192×192 的 RGB565 图像，供 LCD 显示、检测模型预处理和车牌区域裁剪使用。

6.4.2 端侧数据预处理模块

端侧数据预处理模块负责将原始摄像头图像转换为神经网络模型所需的输入格式。由

于系统包含车牌检测和字符识别两个模型，因此预处理分为检测模型输入预处理和识别模型输入预处理两部分。

（1）检测模型预处理：camera_frame_to_model_input() 将 RGB565 像素转换为 RGB888 三通道数据，再按模型量化参数转换为 int8，形成 NHWC 排列的 192×192×3 输入张量。量化方式为 uint8 0～255 减去 128，得到 -128～127 的 int8 数据。

（2）图像方向处理：在单帧处理流程中，可根据 camera_vflip_enabled_debug 对摄像头帧进行垂直翻转，以适配实际摄像头安装方向。

（3）识别模型预处理：车牌检测完成后，license_plate_display_lprnet_update() 根据检测框从原图裁剪车牌区域，并向外扩展一定边距；随后使用双线性插值生成 94×24 灰度图，再转换为 int8 输入供 LPRNet 使用。

（4）调试与显示：识别模型输入灰度图会同步绘制到 LCD 的放大窗口中，同时记录裁剪坐标、灰度最小值、最大值和均值，便于定位识别效果问题。

6.4.3 后处理与决策模块

后处理与决策模块负责把神经网络的原始输出转换为可用业务结果，并根据结果执行显示、发送和跟踪控制。该模块包含检测结果后处理、字符识别解码、结果稳定滤波和云台控制决策。

（1）检测结果后处理：plate_postprocess() 对两个检测头输出进行 Anchor 解码，将 int8 输出反量化为置信度和边界框坐标；随后根据置信度阈值过滤候选框，并使用 NMS 去除重叠框，最终输出车牌检测框数组 plate_dets 和检测数量 det_num。

（2）字符识别解码：license_plate_lprnet_decode_output() 根据 LPRNet 输出的 7 个字符位置和 65 类字符概率，逐位选择最高得分类别，并生成车牌 UTF-8 文本和 ASCII 调试格式。首位按省份简称类别解码，其余位置按字母数字类别解码。

（3）结果稳定策略：为了降低单帧误识别影响，app_vision.c 中维护 3 帧识别结果窗口，对每个字符位置进行投票。当各位置达到最小投票数后，才发布稳定结果并允许 UART 发送。

（4）云台跟踪决策：gimbal_motor_track_detections() 选取最高置信度检测框，计算车牌中心相对画面中心的偏差；若偏差超过死区，则按比例计算 yaw/pitch 目标增量，并通过 CAN2 发送位置控制命令，实现车牌目标居中跟踪。

6.4.4 人机交互模块

人机交互与通信反馈模块负责系统运行状态、识别结果和执行状态的可视化显示，同时实现识别结果向云平台的输出反馈。该模块主要由 LCD 显示、串口通信和云台状态交互组成。

（1）LCD 显示：系统在 RGB LCD 上实时显示摄像头原始图像、车牌检测框、车牌裁剪灰度图、原始识别结果以及滤波后的稳定识别结果。显示区域通过 app_vision.c 中的坐标宏统一规划，便于现场观 察图像采集、目标检测和字符识别效果。

（2）串口与云平台通信：当车牌识别结果经过多帧滤波并达到稳定状态后，系统通过 UART4 将 ASCII 格式的车牌结果发送至 ESP32 模块，并由 ESP32 进一步上传至云平台。发送数据以回车换行作为结束标志，同时程序会记录上一次发送结果，避免同一车牌号被重复上传。

（3）云台交互：云台模块通过 CAN2 与电机节点通信，初始化时完成工作模式配置和电机使能；运行过程中，系统根据车牌检测框中心与图像中心的偏差计算控制目标，并向 yaw、pitch 电机发送位置指令。该部分使系统能够根据视觉识别结果驱动执行机构动作，实现“图像感知—结果识别—云台跟踪”的闭环交互。

7 系统测试评估

7.1 系统测试与性能评估

为验证系统是否满足停车场车牌识别、运动控制和低功耗部署的设计要求，分别从端侧 AI 推理性能、通信稳定性、运动控制实时性、建图与底盘协同能力以及系统连续运行稳定性等方面进行了测试。测试结果表明，系统各模块能够按照设计架构稳定工作，整体达到了预期设计需求，如表 7-1 所示。

表 7-1　边缘部署环境

测试项目	性能设计需求	测试结果	达标情况
端侧车牌检测	GD32H759 应能够完成车牌检测模型部署与端侧推理，不依赖上位机或 GPU 平台	YOLO 车牌检测模型输入尺寸为 192×192×3，采用 int8 量化部署，模型参数量为 316352，模型占用约 316 KB	达标
端侧字符识别	系统应能够完成车牌字符识别，并输出稳定识别结果	LPRNet 字符识别模型输入尺寸为 94×24×1，采用 int8 量化部署，模型参数量为 155896，模型占用约 156 KB	达标
模型存储占用	检测模型和识别模型应满足 GD32H759 端侧部署的存储资源要求	两个模型总占用约 472 KB，能够适配 GD32H759 的 Flash 和 RAM 资源	达标
推理内存占用	模型运行时 RAM 占用应控制在系统可承受范围内	YOLO 静态缓存约 357 KB，LPRNet 静态缓存约 83 KB，满足系统运行需求	达标
通信性能	视觉板、电机控制板和 ESP32 之间应实现稳定通信	UART 用于车牌号和状态上传，CAN 用于目标位置、速度指令和状态反馈，通信链路稳定	达标
电机控制实时性	电机控制板应能够完成实时闭环控制和安全检测	GD32H759I 实现 20 kHz FOC 闭环控制和 1 kHz 安全检测，可完成 PWM 输出、编码器反馈和故障保护	达标
建图与底盘协同	RK3588 建图模块与底盘驱动模块应能协同完成导航和运动执行	RK3588 负责激光雷达 SLAM 建图、定位与路径规划，底盘模块通过 CAN 完成速度、转向执行和里程计反馈	不稳定，暂不达标
系统稳定性	系统应能够连续完成“感知-通信-控制-执行”闭环流程	各模块能够稳定完成车牌识别、状态上传、控制指令传输、运动执行和反馈闭环	达标

7.2端侧 AI 推理性能评估

系统采用 GD32H759 作为端侧视觉推理核心，完成车牌检测和字符识别任务。车牌检测模型采用轻量化 YOLO 结构，输入尺寸为 192×192×3，并进行 int8 量化部署；字符识别模型采用 LPRNet 结构，输入尺寸为 94×24×1，同样采用 int8 量化方式。根据模型转换报告，YOLO 模型占用约 316 KB，LPRNet 模型占用约 156 KB，两个模型总占用约 472 KB，能够适配 GD32H759 的片上资源和系统存储需求。

测试结果说明，系统能够在端侧完成图像采集、预处理、车牌检测、字符识别、结果显示和稳定结果输出如图 7-1 所示，不需要依赖 PC 端或高功耗 GPU 平台，满足低功耗、低成本端侧 AI 部署的设计目标。

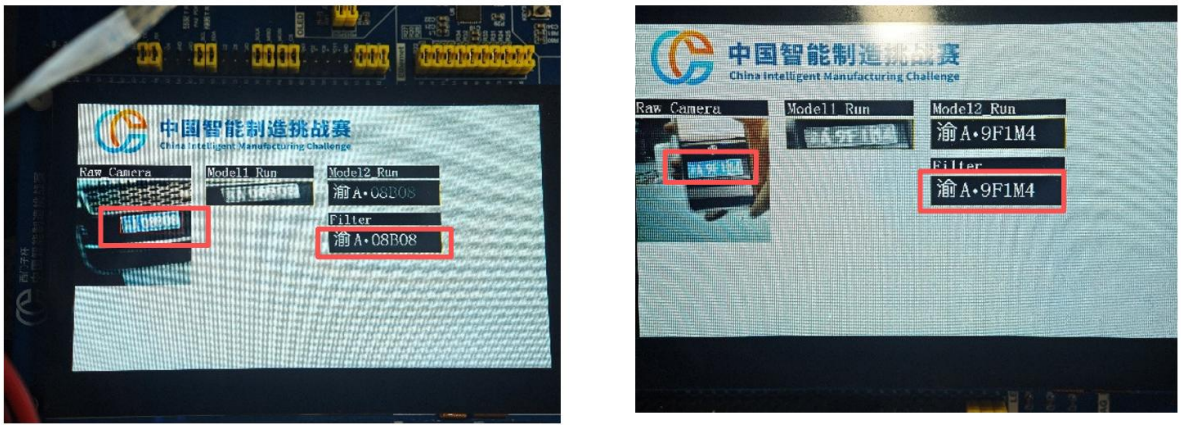


图 7-1 端侧 AI 部署推理结果

7.3通信与控制性能评估

系统采用 UART 和 CAN 两类通信方式实现多模块协同。其中，GD32H759 视觉推理板通过 UART 向 ESP32 通信板输出稳定车牌号和系统状态信息，ESP32 负责无线通信和结果上传；视觉推理板同时通过 CAN 总线向电机控制板发送云台目标位置和速度指令，如图 7-2 所示。电机控制板接收控制指令后，完成状态机切换、PWM 输出、编码器反馈采集和 FOC 闭环控制。

测试表明，CAN 总线能够满足控制指令和状态反馈的实时交互需求，UART 链路能够稳定完成识别结果上传。各模块之间数据流向清晰，通信关系符合系统架构设计。



图 7-2　系统云台结构图

7.4运动控制与安全保护评估

电机控制板以 GD32H759I 为主控，完成电机驱动和运动控制任务。系统设计中包含 20 kHz FOC 闭环控制、1 kHz 安全检测、PWM 输出、编码器/霍尔反馈采集和状态机控制，如图 7-3 所示。测试结果表明，电机控制板能够根据 CAN 指令完成云台回中、回位、速度模式切换和故障处理等功能，控制逻辑稳定。

同时，系统设计了过流、过压、过温、欠压、丢步和看门狗保护机制，提高了运动控制过程中的安全性和可靠性，满足停车场巡检和移动平台运行需求。

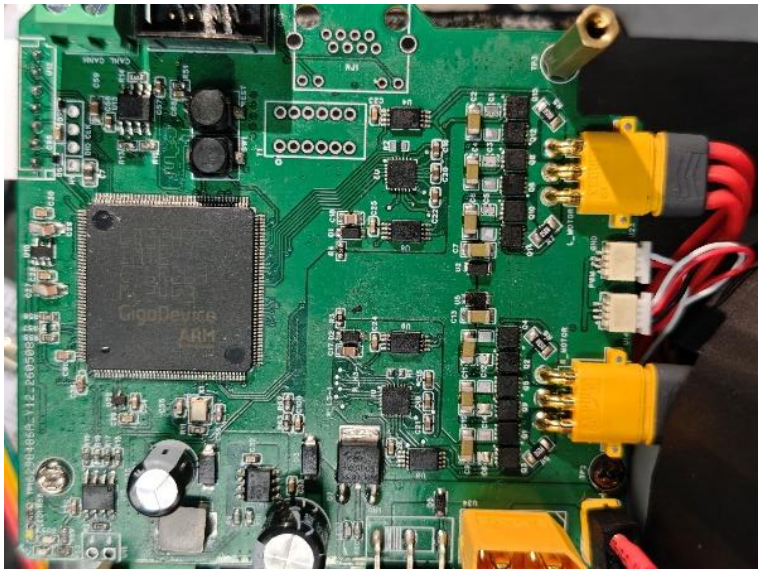


图 7-3　GD32H759I 的双轴电机驱动板

7.5综合评价

综合测试结果表明，本系统实现了车牌识别、通信上传、运动控制、激光雷达建图和底盘执行的完整闭环，系统实物图如图 7-4 所示。端侧 AI 模型经过轻量化和 int8 量化后，占用空间较小，能够在 GD32H759 平台上部署运行；多控制器协同架构降低了单一高算力平台的依赖，有利于降低系统功耗和硬件成本；CAN 总线实现了识别结果、控制指令和状态反馈之间的稳定交互。

因此，系统整体达到了低功耗、低成本、可扩展、可实时控制的设计需求，具备在中小型停车场、移动巡检平台和车牌识别场景中应用的可行性。

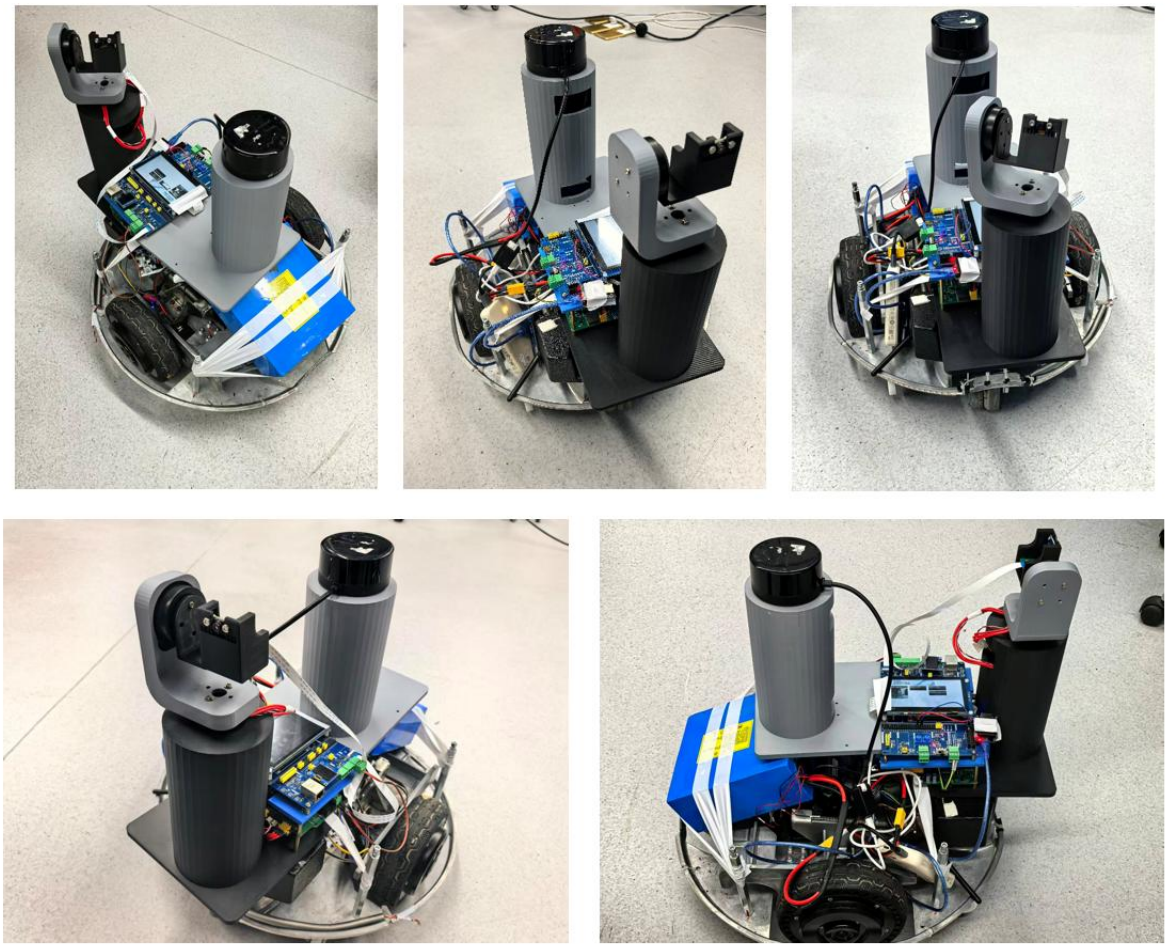


图 7-4　系统总体实物图

8 模型可解释性分析

本系统采用“先检测、后识别”的两阶段视觉流水线：首先由 YOLO-FastestV2 在摄像头图像中定位车牌区域，随后将检测框裁剪、缩放、灰度化并输入 LPRNet Tiny 完成车牌字符识别。由于 YOLO 检测框会进一步决定车牌裁剪范围、LPRNet 输入质量、LCD 显示叠加位置和二轴云台控制偏差，因此检测模型的定位解释性直接影响后续识别与控制链路。LPRNet 输出则直接决定最终车牌号码，其逐字符概率分布、规则约束和多帧投票机制构成了识别结果可信度评估的重要依据。

8.1 YOLO-FastestV2 模型

YOLO-FastestV2 在本系统中承担车牌检测任务，其目标是在复杂停车场图像中快速定位车牌区域。与通用目标检测任务相比，车牌检测具有目标尺度较小、长宽比较固定、字符纹理密集、背景干扰较多等特点。因此，解释 YOLO-FastestV2 的关键在于说明模型如何从局部边缘、矩形边框、字符排列结构和车牌底色差异中形成目标响应，并进一步通过检测头输出候选框与置信度。

8.1.1 输入预处理与坐标映射

设摄像头采集到的原始图像为 I，图像高度和宽度分别为 H_0 和 W_0。由于 GD32H759 端部署的检测模型输入尺寸固定，系统首先将原始图像通过等比例缩放与填充处理转换为 192×192 输入图像。该处理方式能够避免直接拉伸造成车牌宽高比例失真，尤其适用于车牌这类具有固定几何结构的小目标检测任务。

$$I \in \mathbb{R}^{H_0 \times W_0 \times 3} \tag{8-1}$$

$$X \in \mathbb{R}^{192 \times 192 \times 3} \tag{8-2}$$

若原始图像到模型输入空间的缩放比例为 r，填充偏移量为 (dx, dy)，则原图坐标 (x0, y0) 映射至模型输入空间后的坐标为：

$$x = rx_0 + d_x, y = ry_0 + d_y \tag{8-3}$$

模型输出坐标反向恢复至原始图像空间时，可表示为：

$$x_0 = \frac{x - d_x}{r}, y_0 = \frac{y - d_y}{r} \tag{8-4}$$

该坐标映射过程是检测模型与后续车牌裁剪、LCD 叠加显示以及云台控制之间建立

联系的基础。若坐标反变换存在偏差，即使模型在 192×192 输入空间中检测正确，也可能导致原图裁剪位置偏移，最终影响字符识别。

在端侧部署阶段，输入图像还需要由 uint8 像素转换为 int8 量化输入。设原始像素值为 p∈[0,255]，量化尺度为 s，零点为 z，则标准量化过程为：

$$q = \text{round}\left(\frac{p/255}{s}\right) + z \tag{8-5}$$

本系统输入量化采用 $s = 1/255$、$z = -128$，因此可近似写为：

$$q = p - 128 \tag{8-6}$$

这种线性平移方式简化了 MCU 端预处理流程，减少了浮点运算开销，使模型输入与 GD NN Runtime 的 INT8 推理格式保持一致。

8.1.2 卷积特征提取过程

YOLO-FastestV2 通过轻量化卷积结构完成车牌目标特征提取。对于第 1 层卷积，设输入特征图为 $X^{(l-1)}$，卷积核权重为 $W^{(l)}$，偏置为$b^{(l)}$，则输出特征图在空间位置 (i,j) 和通道 c 上的计算可表示为：

$$Z_{i,j,c}^{(l)} = \sum_{u=1}^{K}\sum_{v=1}^{K}\sum_{m=1}^{C_{l-1}} W_{u,v,m,c}^{(l)} X_{i+u,j+v,m}^{(l-1)} + b_c^{(l)} \tag{8-7}$$

卷积操作通过局部感受野对输入图像进行滑动加权求和。浅层卷积主要响应车牌边缘、字符笔画和颜色突变；中层卷积逐步形成车牌矩形轮廓、字符排列方向和局部纹理组合；高层卷积则形成对“车牌目标”更具语义性的响应。

经过批归一化和非线性激活后，输出特征可写为：

$$Y_{i,j,c}^{(l)} = \phi\left(\gamma_c \frac{Z_{i,j,c}^{(l)} - \mu_c}{\sqrt{\sigma_c^2 + \varepsilon}} + \beta_c\right) \tag{8-8}$$

其中，μ_c 和 σc^2分别为通道均值与方差，γ_c 和 βc 为可学习参数，φ(·)为非线性激活函数。批归一化能够稳定不同层之间的特征分布，非线性激活则增强模型对光照变化、车牌倾斜、背景遮挡等复杂场景的表达能力。

从可解释性角度看，YOLO-FastestV2 并非直接记忆某一车牌样本，而是通过多层卷积逐步提取从低级视觉模式到高级目标语义的层级特征。当某一区域同时具备“矩形边界明显、内部存在字符纹理、底色或亮度分布符合车牌先验”等特征时，该区域在检测头中的目标置信度会升高。

8.1.3 检测头输出与边界框推导

YOLO-FastestV2 采用基于网格和 Anchor 的检测机制。设某一尺度的检测输出特征图为$P^{(s)}$，其中s 表示输出尺度，H_s 和 W_s 分别表示该尺度特征图的高度与宽度。本文模型每个网格位置输出多个 Anchor 对应的边界框回归量、目标置信度和类别置信度。

$$P^{(s)} \in \mathbb{R}^{H_s \times W_s \times 16} \tag{8-9}$$

对于第 (i,j) 个网格单元和第 a 个 Anchor，检测头输出可表示为：

$$\mathbf{t}_{i,j,a} = \left(t_x, t_y, t_w, t_h, t_o, t_c\right) \tag{8-10}$$

其中，t_x 和 ty 表示中心点偏移量，t_w 和 t_h 表示宽高回归量，to 表示目标存在置信度，t_c 表示车牌类别置信度。设 Sigmoid 函数为：

$$\sigma(t) = \frac{1}{1+e^{-t}} \tag{8-11}$$

则检测框中心点可按如下方式解码：

$$b_x = (2\sigma(t_x) - 0.5 + j) \cdot S_s \tag{8-12}$$

$$b_y = \left(2\sigma\left(t_y\right) - 0.5 + i\right) \cdot S_s \tag{8-13}$$

其中，Ss 为该检测尺度的步长。若第 a 个 Anchor 的先验宽高为 (pa^w, pa^h)，则检测框宽高可表示为：

$$b_w = \left(2\sigma(t_w)\right)^2 p_a^w \tag{8-14}$$

$$b_h = \left(2\sigma(t_h)\right)^2 p_a^h \tag{8-15}$$

由此得到候选检测框：

$$B_{i,j,a} = \left(b_x, b_y, b_w, b_h\right) \tag{8-16}$$

上述公式说明，模型并不是直接输出车牌框左上角和右下角坐标，而是在每个网格位置基于 Anchor 先验预测相对偏移量，再通过解码公式还原为输入图像坐标。该机制具有明确的可解释性：网格单元负责判断目标中心是否位于其附近，Anchor 负责提供不同尺度与长宽比的候选先验，回归分支负责对候选框进行细化修正。

候选框的综合置信度可表示为：

$$S_{i,j,a} = \sigma(t_o) \cdot \sigma(t_c) \tag{8-17}$$

由于本系统检测类别为车牌，$\sigma(tc)$可解释为候选区域属于车牌类别的概率，$\sigma(to)$可解释为该 Anchor 位置存在目标的概率。二者相乘能够同时约束“是否存在目标”和“目标是否为车牌”。

8.1.4 置信度筛选、NMS 与最终检测框

检测头通常会产生大量候选框，其中多个候选框可能同时覆盖同一车牌区域。因此，

模型后处理首先根据置信度阈值进行筛选：

$$\mathcal{B}' = \{B_k \mid S_k \geq \theta_{conf}\} \tag{8-18}$$

随后，系统通过非极大值抑制删除高度重叠的冗余候选框。两个候选框 Bm 和 Bn 的交并比定义为：

$$IoU(B_m, B_n) = \frac{|B_m \cap B_n|}{|B_m \cup B_n|} \tag{8-19}$$

若某一低置信度候选框与高置信度候选框的IoU超过阈值 θnms，则认为二者指向同一目标，并删除低置信度候选框：

$$B_n \text{ is suppressed if } IoU(B_m, B_n) > \theta_{nms}, S_m > S_n \tag{8-20}$$

经过 NMS 后得到最终车牌检测框：

$$B^* = (x^*, y^*, w^*, h^*) \tag{8-20}$$

该检测框同时承担三个功能：第一，用于 LCD 画面叠加显示；第二，用于裁剪车牌区域并输入 LPRNet；第三，用于计算目标中心与画面中心的偏差，从而驱动二轴云台调整摄像头方向。设图像中心为 $(W/2, H/2)$，检测框中心为 $(x*, y*)$，则云台控制偏差为：

$$e_x = x^* - \frac{W}{2}, \quad e_y = y^* - \frac{H}{2} \tag{8-22}$$

其中，e_x 主要对应云台偏航轴调整量，e_y 主要对应云台俯仰轴调整量。由此可见，YOLO-FastestV2 输出的检测框不仅是识别任务的中间结果，也是系统视觉感知与执行控制闭环中的关键变量。

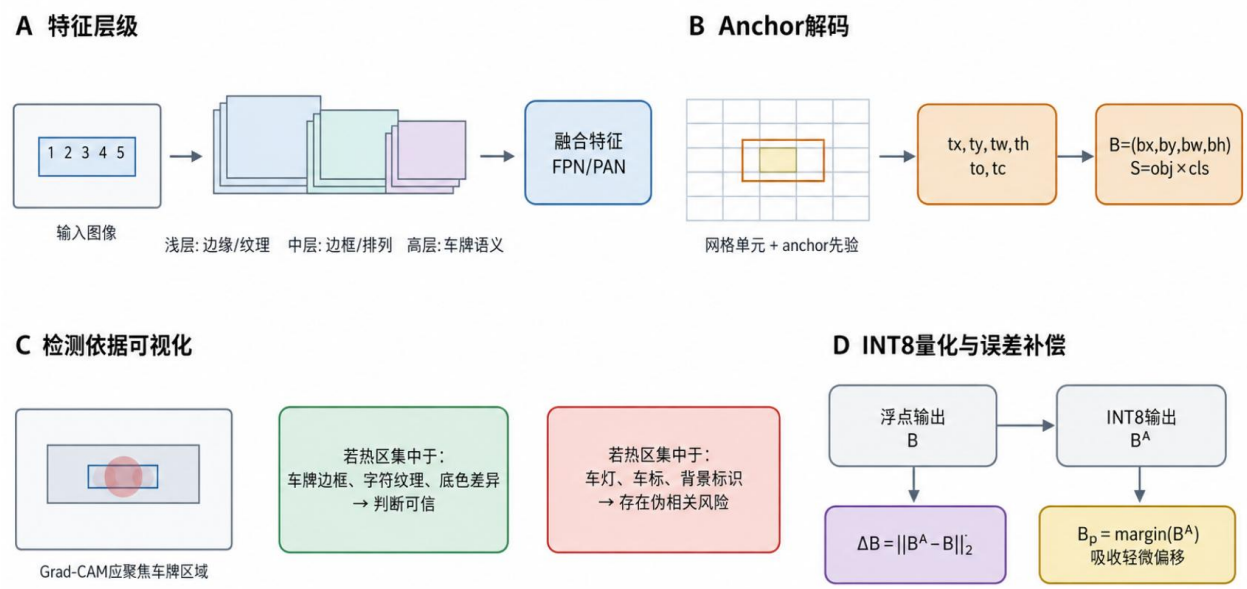


图 8-2　YOLO-FastestV2 检测模型可解释性框架图。

为了进一步解释 YOLO-FastestV2 为何将某一区域判断为车牌，可采用特征响应可视化和梯度类激活图方法。设模型某一高层特征图为 A_k，候选框综合置信度为 S，则该置

信度相对于特征图的通道权重可表示为：

$$\alpha_k = \frac{1}{Z}\sum_i\sum_j \frac{\partial S}{\partial A_{i,j}^k} \tag{8-23}$$

基于该权重，可得到目标检测热力图：

$$L_{\text{YOLO}} = \text{ReLU}\left(\sum_k \alpha_k A^k\right) \tag{8-24}$$

若热力图高响应区域主要集中在车牌边框、字符纹理和车牌底色区域，则说明模型判断依据与任务目标一致；若高响应区域集中在车灯、车标、车身反光或背景标识，则说明模型可能存在背景依赖或伪相关风险。

结合停车场应用场景，YOLO-FastestV2 解释结果可从四个方面进行判定：第一，在正常光照条件下，高响应区域应覆盖车牌整体矩形区域；第二，在远距离或轻微模糊场景中，模型应优先响应车牌边框和字符排列结构；第三，在倾斜或旋转车牌中，高层特征应对车牌区域保持连续响应；第四，在多车同框场景中，不同候选框置信度应随车牌清晰度、尺度大小和遮挡程度合理变化。

8.1.5 INT8 量化误差与检测解释性

由于 YOLO-FastestV2 部署于 GD32H759 端侧平台，模型需要采用 INT8 量化推理。设浮点特征值为 x_f，量化值为 x_q，反量化后的近似浮点值为 $\hat{x}_f$，则量化和反量化过程可表示为：

$$x_q = \text{clip}\left(\text{round}\left(\frac{x_f}{s}\right) + z\right) \tag{8-25}$$

$$\hat{x}_f = s(x_q - z) \tag{8-26}$$

量化误差定义为：

$$\varepsilon_q = x_f - \hat{x}_f \tag{8-27}$$

在均匀量化条件下，单层量化误差通常满足：

$$|\varepsilon_q| \le \frac{s}{2} \tag{8-28}$$

但在多层卷积神经网络中，量化误差会经过卷积、激活和特征融合逐层传播，最终可能表现为检测框中心点或宽高的轻微偏移。设 INT8 模型输出检测框为 $\hat{B}$，浮点参考模型检测框为 B，则检测框偏差可表示为：

$$\Delta B = \left\|\hat{B} - B\right\|_2 \tag{8-29}$$

为了降低检测框小幅偏移对后续字符识别的影响，本文在车牌裁剪阶段设置边界扩展 margin。设检测框为 $B = (x, y, w, h)$，margin 比例为 ρ，则扩展后的裁剪框为：

$$B_\rho = (x - \rho w,\ y - \rho h,\ (1+2\rho)w,\ (1+2\rho)h) \tag{8-30}$$

通过该方式，即使 YOLO 检测框在复杂场景或 INT8 量化条件下出现轻微偏移，系统仍可尽量保留完整车牌字符区域，降低级联模型中的误差放大风险。

综上，YOLO-FastestV2 的可解释性主要体现在三个层面：其一，结构上通过轻量化卷积和多尺度检测头提取车牌目标特征；其二，数学上通过网格、Anchor、回归量和置信度共同生成检测框；其三，工程上通过阈值筛选、NMS、坐标反变换、margin 裁剪和量化误差补偿，将检测输出转化为可用于字符识别和云台控制的稳定变量。

8.2 LPRNet 模型可解释性

LPRNet Tiny 在本系统中承担车牌字符识别任务。与 YOLO-FastestV2 面向完整场景图像不同，LPRNet 的输入来自车牌检测框裁剪后的局部车牌图像。因此，其可解释性不仅取决于模型本身的字符判别能力，也受到 YOLO 检测框准确性、裁剪 margin、灰度化、缩放和量化处理的影响。

8.2.1 识别输入形成过程

设 YOLO-FastestV2 输出的最终检测框为 $B*$，加入 margin 扩展后得到裁剪框 $B\rho$。根据该裁剪框从原始图像中提取车牌区域，可表示为：

$$R = \mathrm{Crop}(I, B_\rho) \tag{8-31}$$

随后，系统将裁剪区域转换为灰度图，并统一缩放至 94×24，作为 LPRNet Tiny 的输入：

$$X_{lpr} \in \mathbb{R}^{24\times 94\times 1} \tag{8-32}$$

灰度化过程可表示为：

$$G = 0.299R_c + 0.587G_c + 0.114B_c \tag{8-33}$$

其中，Rc、Gc和Bc分别表示彩色图像的红、绿、蓝通道。灰度化能够降低输入通道数，减少端侧计算量，同时保留字符笔画、车牌边框和底色亮度差异等关键识别信息。在 INT8 部署阶段，灰度像素值 $g \in [0,255]$ 同样转换为：

$$q_g = g - 128 \tag{8-34}$$

该处理方式使 LPRNet 与 YOLO 输入量化逻辑保持一致，便于在 MCU 端统一实现预处理。

8.2.2 前向传播与逐字符概率推导

LPRNet Tiny 采用全卷积结构进行车牌字符识别。设输入车牌图像为 X_lpr，模型参数为 θ，则卷积网络提取到的特征可表示为：

$$F = f_\theta(X_{lpr}) \tag{8-35}$$

与一般图像分类模型不同，车牌识别需要输出字符序列。因此，LPRNet 最终输出不是单一类别概率，而是按字符位置排列的多类别 logits。设车牌字符长度为 T，字符类别数为 C，则输出可表示为：

$$Z \in \mathbb{R}^{T\times C} \tag{8-36}$$

对于第 t 个字符位置和第 c 个字符类别，模型输出 logit 为 z(t,c)。经 Softmax 函数归一化后，该位置属于类别 c 的概率为：

$$p_{t,c} = \frac{\exp(z_{t,c})}{\sum_{k=1}^{C}\exp(z_{t,k})} \tag{8-37}$$

第 t 位字符的预测结果为：

$$\hat{y}_t = \arg\max_{c\in C} p_{t,c} \tag{8-38}$$

整牌预测序列为：

$$\hat{Y} = (\hat{y}_1, \hat{y}_2, \ldots, \hat{y}_T) \tag{8-39}$$

由此可见，LPRNet 具有较强的位置可解释性。每一个字符位均对应一个独立的类别概率分布，系统不仅可以输出最终车牌号，还可以输出每一位字符的最大概率、次大概率和置信度间隔。当某一字符位最大概率较低，或最大概率与次大概率接近时，说明该位置存在识别不确定性。

8.2.3 损失函数与整牌准确率

在训练阶段，若采用固定字符位置监督，设真实车牌标签为 $Y = (y1, y2, \ldots, yT)$，则 LPRNet 训练目标可表示为多位置交叉熵损失：

$$Y = (y_1, y_2, \ldots, y_T) \tag{8-40}$$

若考虑不同字符位的重要性或难度差异，可引入位置权重 ωt，得到加权损失函数：

$$\mathcal{L}_{lpr} = -\sum_{t=1}^{T}\log p_{t,y_t} \tag{8-41}$$

该损失函数的含义是模型需要在每一个字符位置上提高真实字符类别概率，并降低其他候选字符概率。对于整牌识别而言，任意一个字符错误都会导致整牌识别失败，因此整牌正确概率可近似表示为各位置字符正确概率的乘积：

$$P(\hat{Y} = Y \mid X_{lpr}) = \prod_{t=1}^{T} p_{t,y_t} \tag{8-42}$$

若每位字符平均识别准确率为 p，车牌长度为 T，则整牌准确率近似为：

$$Acc_{plate} \approx p^{T} \tag{8-43}$$

该公式解释了为什么字符级准确率较高时，整牌准确率仍可能明显降低。以 7 位普通车牌为例，即使单字符准确率较高，随着字符位数增加，整牌完全正确概率仍会下降。因此，在工程应用中不能仅依赖单帧最大概率输出，而需要结合规则校验、多帧投票和置信度阈值提高最终输出稳定性。

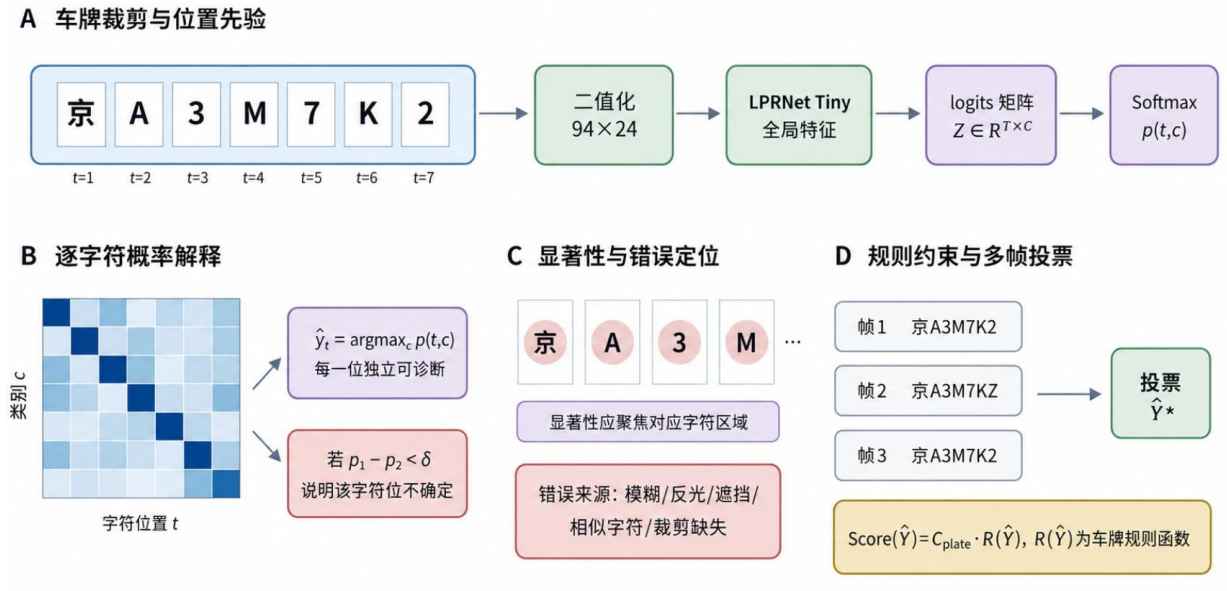


图 8-3　LPRNet Tiny 识别模型可解释性框架图字符位置与视觉区域

车牌图像具有明显的横向序列结构，即字符从左到右排列。设输入车牌图像宽度为 $W = 94$，字符长度为 T，则第 t 个字符在理想情况下大致对应的横向区域可表示为：

$$\Omega_t = \left[\frac{(t-1)W}{T}, \frac{tW}{T}\right] \tag{8-44}$$

尽管卷积网络会通过感受野聚合相邻区域信息，但第 t 位字符预测仍主要依赖其对应的局部横向区域及周边上下文。因此，当某一字符识别错误时，可以通过观察该字符对应区域是否存在模糊、遮挡、过曝、欠曝、裁剪缺失或相似字符干扰来解释错误来源。

进一步地，可采用梯度显著性图解释某一字符位的判别依据。对于第 t 位预测字符 $\hat{y}t$，其 logit 为 $z(t, \hat{y}t)$，对输入图像求梯度可得：

$$M_t = \left| \frac{\partial z_{t,\hat{y}_t}}{\partial X_{lpr}} \right| \tag{8-45}$$

其中，Mt 表示第 t 位字符预测对输入像素的敏感程度。若显著性区域集中在该字符的笔画位置，则说明模型主要依据字符本身进行判断；若显著性区域偏向车牌边框、背景噪声或其他字符区域，则提示模型可能受到裁剪、噪声或上下文干扰。

也可采用类激活图思想对 LPRNet 中间特征进行解释。设某一卷积层特征图为 Ak，第 t 位目标字符类别为 c，则通道权重可表示为：

$$\alpha_k^{t,c} = \frac{1}{Z} \sum_i \sum_j \frac{\partial z_{t,c}}{\partial A_{i,j}^k} \tag{8-46}$$

$$L_{LPR}^{t,c} = \mathrm{ReLU}\left(\sum_k \alpha_k^{t,c} A^k \right) \tag{8-47}$$

通过比较不同字符位的热力图，可以判断模型是否按照车牌字符顺序逐位聚焦。例如，第一位省份简称的热力图应主要集中于车牌左侧汉字区域，第二位字母应集中在汉字右侧的字母区域，后续数字或字母应沿水平方向依次分布。若热力图顺序混乱，则可能说明输入车牌倾斜、裁剪不完整或模型对字符位置编码不足。

8.2.4 字符置信度、规则约束与多帧投票

为了提高端侧识别稳定性，LPRNet 输出后需要进行字符解码、格式校验和多帧滤波。设单帧识别得到的序列为：

$$\hat{Y}^{(n)} = \left(\hat{y}_1^{(n)}, \hat{y}_2^{(n)}, \ldots, \hat{y}_T^{(n)} \right) \tag{8-48}$$

其中，n 表示第 n 帧。第 t 位字符的置信度为：

$$C_t^{(n)} = \max_c p_{t,c}^{(n)} \tag{8-49}$$

整牌置信度可采用乘积形式：

$$C_{plate}^{(n)} = \prod_{t=1}^{T} C_t^{(n)} \tag{8-50}$$

也可采用对数求和形式，以避免乘积过小：

$$\log C_{plate}^{(n)} = \sum_{t=1}^{T} \log C_t^{(n)} \tag{8-51}$$

在车牌规则约束方面，普通中国车牌通常具有明确的位置先验，例如第 1 位为省份简称，第 2 位为大写字母，后续位多为字母或数字。因此，可定义规则函数：

$$R(\hat{Y}) = \begin{cases} 1, & \hat{Y} \text{ 满足车牌编码规则} \\ 0, & \hat{Y} \text{ 不满足车牌编码规则} \end{cases} \tag{8-52}$$

最终输出评分可综合考虑模型置信度与规则约束：

$$Score(\hat{Y}) = C_{plate} \cdot R(\hat{Y}) \tag{8-53}$$

对于连续多帧识别结果，系统可采用加权投票方式提升稳定性。设最近 N 帧中第 t 位字符预测为 $\hat{y}t^{(n)}$，对应权重为 wn，则字符 c 在第 t 位的投票得分为：

$$V_{t,c} = \sum_{n=1}^{N} w_n \cdot \mathbf{1}\left(\hat{y}_t^{(n)} = c\right) \tag{8-54}$$

最终第 t 位字符输出为：

$$\hat{y}_t = \arg\max_{c \in \mathcal{C}} p_{t,c} \tag{8-55}$$

整牌稳定输出为：

$$\tilde{Y} = (\tilde{y}_1, \tilde{y}_2, \ldots, \tilde{y}_T) \tag{8-56}$$

该过程能够解释为什么系统在单帧识别偶发错误的情况下，仍可以通过连续帧结果获得更稳定的车牌号。当某一帧因运动模糊、反光或云台调整造成错误识别时，只要相邻帧中大多数识别结果保持一致，多帧投票即可抑制异常输出。

8.2.5 LPRNet 误差来源

LPRNet 识别错误通常来自四类因素。第一类是输入裁剪误差，即 YOLO 检测框偏移导致字符边缘缺失或车牌区域包含过多背景；第二类是图像质量退化，包括运动模糊、弱光、过曝、反光和遮挡；第三类是字符形态相似，例如“0”和“D”、“8”和“B”、“1”和“I”等字符在低分辨率条件下容易混淆；第四类是规则外样本，例如新能源车牌、特殊车牌或污损车牌，其字符长度和排列方式可能与普通蓝牌存在差异。

从概率输出角度看，若某一字符位最大概率与次大概率之间差距较小，则说明该字符位识别可信度不足。设最大概率类别为 c1，次大概率类别为 c2，不确定性条件可写为：

$$p_{t,c_1} - p_{t,c_2} < \delta \tag{8-57}$$

其中，δ 为置信度间隔阈值。当该条件成立时，说明模型在两个相似字符之间存在明显不确定性。此时系统可结合车牌编码规则、多帧投票结果和上下文先验进行修正，而不宜直接输出单帧最大概率字符。

8.2.6 检测—识别级联模型

YOLO-FastestV2 与 LPRNet Tiny 并非两个相互孤立的模型，而是构成级联式车牌识别流水线。其整体推理链路可表示为：

$$I \rightarrow X \rightarrow B^{*} \rightarrow B_{\rho} \rightarrow X_{lpr} \rightarrow \hat{Y} \rightarrow \tilde{Y} \tag{8-58}$$

其中，I 为原始图像，X 为 YOLO 输入图像，B*为检测框，$B\rho$为扩展裁剪框，X_lpr为 LPRNet 输入图像，Ŷ 为单帧识别结果，Ỹ 为多帧稳定输出结果。

该流程表明，最终车牌识别结果可以被拆解为多个可解释环节：车牌目标是否被检测到、检测框是否覆盖完整车牌、裁剪图像是否清晰、每位字符概率是否足够集中、车牌编码规则是否满足、多帧结果是否稳定一致。相较于端到端直接输出车牌号的黑箱模型，两阶段级联方案具有更强的工程可解释性和调试便利性。

当系统输出错误车牌号时，可以沿着上述链路逐步定位错误来源：若检测框偏移，则主要问题来自 YOLO 定位；若检测框正确但字符局部模糊，则主要问题来自图像采集质量；若字符概率分布分散，则主要问题来自 LPRNet 判别不确定性；若单帧错误但多帧稳定正确，则说明后处理滤波发挥了纠错作用。

综上，LPRNet Tiny 的可解释性主要体现在三个方面：第一，模型输出具有逐字符位置概率分布，可直接分析每一位字符的置信度和混淆关系；第二，梯度显著性图和类激活图能够揭示模型是否真正关注字符笔画区域；第三，车牌规则约束与多帧投票机制将单帧神经网络输出转化为更稳定、更符合实际业务逻辑的车牌识别结果。结合 YOLO-FastestV2 的检测框解释，本文所采用的车牌检测—识别模型具有较清晰的推理链路和较好的工程可解释性，能够满足停车智能管理系统对端侧实时性、稳定性和可调试性的综合需求。

9 总结与展望

本项目围绕“基于 GD32H759 的二轴云台停车智能管理系统”开展设计与实现，面向停车场及道路违停等典型应用场景，构建了一套“边缘 AI 视觉感知 + 云台目标跟踪 + 移动平台控制 + 上位机协同”的嵌入式智能巡检系统。

本文采用分层解耦的设计方法，构建由 GD32H759 端侧视觉推理单元、云台执行单元、底盘运动控制单元及上位机组成的协同系统，实现感知、决策与执行的分离，提高了系统整体的可扩展性与工程可维护性。系统部署了 YOLO-FastestV2 车牌检测模型与 LPRNet Tiny 字符识别模型，并通过 INT8 量化与轻量化结构设计，将模型总占用压缩至约 472 KB，在保证识别性能的同时满足 GD32H759 嵌入式资源约束，实现了端侧独立运行能力。系统在功能上完成了车牌检测、字符识别、云台目标跟踪、底盘运动控制以及无线通信上传等关键模块开发，形成“图像采集—目标检测—字符识别—目标跟踪—结果反馈”的闭环处理流程。在通信层面，系统通过 CAN 与 UART 实现多模块协同，保证控制指令与识别结果的稳定传输。

系统能够在端侧完成了模型部署与推理测试。结果表明，检测模型与识别模型均可稳定运行，端侧推理流程完整，通信与控制链路可靠，系统能够在无 GPU 依赖条件下完成实时车牌识别与云台控制任务，整体满足低功耗、低成本与实时性的设计目标。

在后续研究与工程优化中，展望几个方向进一步提升系统性能与应用范围：

1) 复杂场景鲁棒性提升

针对夜间、雨雾、强光及遮挡等复杂环境，可引入图像增强算法与多传感器融合机制（如红外、雷达），提升系统整体感知稳定性。

2) 模型性能进一步优化

在现有 INT8 量化基础上，可结合剪枝、蒸馏与结构重参数化等方法，进一步降低模型计算复杂度，提高端侧推理帧率与能效比。

3) 导航与协同控制优化

针对当前 RK3588 建图与底盘协同稳定性不足的问题，可优化 SLAM 参数配置，并引入多传感器融合定位，提高路径规划与运动控制的可靠性。

4) 系统实时性增强

可引入轻量级实时操作系统（RTOS），对视觉推理、通信与电机控制任务进行优先级调度，从而提升多任务并发处理能力与系统实时性。

5) 工程化与应用拓展

在工程落地层面，可进一步进行模块小型化与功耗优化设计，并将系统扩展至园区巡检、智能安防、无人巡逻等多类移动机器人应用场景。

参考文献

[1] LIN J, CHEN W M, LIN Y, et al. MCUNet: Tiny deep learning on IoT devices[C]//Advances in Neural Information Processing Systems. 2020, 33: 11711-11722.

[2] HART P E, NILSSON N J, RAPHAEL B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE Transactions on Systems Science and Cybernetics, 1968, 4(2): 100-107.

[3] ISO. ISO 11898-1:2024 Road vehicles—Controller area network (CAN)—Part 1: Data link layer and physical coding sublayer[S]. Geneva: International Organization for Standardization, 2024.

[4] DURRANT-WHYTE H, BAILEY T. Simultaneous localization and mapping: Part I[J]. IEEE Robotics & Automation Magazine, 2006, 13(2): 99-110.

[5] TEXAS INSTRUMENTS. DRV8300: 100-V three-phase BLDC gate driver: SLVSFG5D[R]. Dallas: Texas Instruments, 2022.

[6] GIGADEVICE SEMICONDUCTOR INC. GD32H73x/75x User Manual[R]. Beijing: GigaDevice Semiconductor Inc.

[7] DOG-QIUQIU. Yolo-FastestV2: Based on YOLO's low-power, ultra-lightweight universal target detection algorithm[CP/OL]. Zenodo, 2021. DOI:10.5281/zenodo.5181503.

[8] SANDLER M, HOWARD A, ZHU M, et al. MobileNetV2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4510-4520.

[9] ZHERZDEV S, GRUZDEV A. LPRNet: License plate recognition via deep neural networks[EB/OL]. arXiv:1806.10447, 2018.

[10] MA N, ZHANG X, ZHENG H T, et al. ShuffleNet V2: Practical guidelines for efficient CNN architecture design[C]//Proceedings of the European Conference on Computer Vision. Cham: Springer, 2018: 116-131.

[11] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.

[12] JACOB B, KLIGYS S, CHEN B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2704-2713.

[13] TEXAS INSTRUMENTS. INA240: -4-V to 80-V, bidirectional, ultra-precise current

sense amplifier with enhanced PWM rejection[R]. Dallas: Texas Instruments, 2018.

[14] TEXAS INSTRUMENTS EUROPE. Field orientated control of 3-phase AC-motors[R]. Freising: Texas Instruments Europe, 1998.

附录

参赛所有材料百度网盘链接：
https://pan.baidu.com/s/1c4fVxKet_cBBo42pKwq0aQ?pwd=5204
提取码：5204

公开数据集链接：https://github.com/detectRecog/CCPD